



# 프로젝트 최종 리뷰

쇼핑몰 리뷰 평점 분류

팀 Konan: 고은비 김태영 박린 장서연

# 목차

---

#01 프로젝트 소개

#02 EDA + 전처리 - 1주차

#03 모델링 - 2~8주차

#04 프로젝트 리뷰




# #01 프로젝트 소개



# #01 프로젝트 소개: 쇼핑몰 리뷰 평점 분류 AI 해커톤

목표: 네이버 쇼핑몰 텍스트 리뷰 데이터셋 ➡ 1, 2, 4, 5 점으로 상품 평점 분류

리더보드 평가 기준: accuracy



The screenshot shows the DAICON event page. At the top left is the DAICON logo. To the right are a search icon, a '구독 안내' (Subscription Guide) button, and a user profile icon. The main content area has a blue background. On the left, the event title '쇼핑몰 리뷰 평점 분류 AI 해커톤' is displayed in large white text. Below it, the topics '알고리즘 | NLP | 분류 | 리뷰 | Accuracy' are listed. Further down, the prize '₩ 상금 : 인증서, 장학금, 스타벅스 기프티콘 등' is shown. The dates '2022.07.11 ~ 2022.08.05 17:59' are listed with a '+ Google Calendar' button. At the bottom left, it says '659명' (659 people) and '마감' (Closed). In the center is a 3D illustration of a modern building with 'DAICON' on the roof, surrounded by trees and a road with cars. On the right side of the page, there is a share icon and a '연습' (Practice) button.

DAICON

구독 안내

## 쇼핑몰 리뷰 평점 분류 AI 해커톤

알고리즘 | NLP | 분류 | 리뷰 | Accuracy

₩ 상금 : 인증서, 장학금, 스타벅스 기프티콘 등

🕒 2022.07.11 ~ 2022.08.05 17:59 + Google Calendar

👤 659명 📅 마감

연습

# #01 프로젝트 소개: 쇼핑몰 리뷰 평점 분류 AI 해커톤

데이콘 [*train.csv, test.csv*]

| train.csv   test.csv   sample_submission.csv   ▾ |      |                                           |                                         |
|--------------------------------------------------|------|-------------------------------------------|-----------------------------------------|
| ≡ Views                                          |      | Grid view ⚙ ▾                             | Hide fields ≡ Filter ≡ Group ▾ Sort ▾ ≡ |
| <input type="checkbox"/>                         | id ▾ | reviews ▾                                 | target ▾                                |
| 1                                                | 0    | 조아요 처음구입 싸게했어요                            | 2                                       |
| 2                                                | 1    | 생각보다 잘 안돼요 매지 바른지 하루밖에 안됐는데 ππ 25천원가량 ... | 1                                       |
| 3                                                | 2    | 디자인은괜찮은데 상품이 금이가서 교환했는데 두번째받은상품도 까...     | 2                                       |
| 4                                                | 3    | 기전에 이 제품말고 이마트 트레이더스에서만 팔던 프리미엄 제품을 ...   | 2                                       |
| 5                                                | 4    | 튼튼하고 손목을 잘 받쳐주네요~                         | 5                                       |



| train.csv   test.csv   sample_submission.csv   ▾ |      |                                               |                                         |
|--------------------------------------------------|------|-----------------------------------------------|-----------------------------------------|
| ≡ Views                                          |      | Grid view ⚙ ▾                                 | Hide fields ≡ Filter ≡ Group ▾ Sort ▾ ≡ |
| <input type="checkbox"/>                         | id ▾ | reviews ▾                                     |                                         |
| 1                                                | 0    | 채소가 약간 시들어 있어요                                |                                         |
| 2                                                | 1    | 발톱 두껍고 단단한 분들 써도 소용없어요 이 테이프 물렁거리고 힘이없어서 ...  |                                         |
| 3                                                | 2    | 부들부들 좋네요 입어보고 시원하면 또 살게요                      |                                         |
| 4                                                | 3    | 이런 1.8 골드 주라니깐 파란개 오네 회사전화걸어도 받지도 않고 머하자는거... |                                         |
| 5                                                | 4    | 검수도 없이 보내구 불량 배송비 5000원 청구하네요 완전별로 별하나도 아까... |                                         |

[naver\_shopping.txt]

## naver\_shopping.txt

- 언어: 한국어
- 출처: 네이버 쇼핑 (<https://shopping.naver.com/>)
- 수집 기간: 2020.06~2020.07
- 데이터 건수: 20만 건

네이버 쇼핑에서 제품별 후기를 별점과 함께 수집한 것입니다. 데이터는 탭으로 분리되어 있으며, 첫번째 필드에는 별점(1 ~ 5), 두번째 필드에는 텍스트가 위치합니다. 긍/부정으로 분류하기 애매한 3점에 해당하는 텍스트들은 제외하였고, 긍정(4 ~ 5점)과 부정(1 ~ 2점)의 비율이 1:1에 가깝도록 샘플링하였습니다.

## 데이터 분포

|              | 별점 | 건수      |
|--------------|----|---------|
| 긍정 (99,963)  | 5  | 81,177  |
|              | 4  | 18,786  |
| 부정 (100,037) | 2  | 63,989  |
|              | 1  | 36,048  |
| 계            |    | 200,000 |

## 데이터 미리 보기

5    배송빠르고 굿  
2    택배가 엉망이네용 저회전 밑에층에 말도없이 놔두고가고  
5    아주좋아요 바지 정말 좋아서2개 더 구매했어요 이가격에 대박입니다. 바느질이 조금 엉성하긴 하지만 편하고 가성비 최고예요.  
2    선물용으로 빨리 받아서 전달했어야 하는 상품이었는데 머그컵만 와서 당황했습니다. 전화했더니 바로주신대했지만 배송도 누락되어있었네요  
5    민트색상 예뻐요. 옆 손잡이는 거는 용도로도 사용되네요 ㅎㅎ  
2    비추합니다 계란 뒤집을 때 완전 불편해요 ππ 코팅도 떨어져나가고 보기에 예쁘고 실용적으로 보였는데 생각보다 진짜 별로입니다.  
1    주문을 11월6에 시켰는데 11월16일에 배송이 왔네요 ㅎㅎㅎ 여기 회사측과는 전화도 안되고 아무런 연락을 받을수가 없으니 답답하신 분들  
2    넉넉한 길이로 주문했는데도 안 맞네요 별로예요  
2    보풀이 계속 매처럼 나오다가 지금은 안나네요~  
2    110인데 전문속옷브랜드 위생팬티105보다 작은듯해요. 불편해요. 밴딩부분이 다 신축성있는 일반실로 되어있어 빅사이즈일에도 빅사이즈같!

<https://github.com/bab2min/corpus/tree/master/sentiment>

## #02 EDA + 전처리



# #02 EDA + 전처리 - 1주차

## #1 EDA

- naver\_shopping.txt → df
- 피쳐: “target”, “reviews”

```
df.head()
```

|   | target | reviews                                           |
|---|--------|---------------------------------------------------|
| 0 | 5      | 배송빠르고 곳                                           |
| 1 | 2      | 택배가 엉망이네용 저희집 밑에층에 말도없이 놔두고가고                     |
| 2 | 5      | 아주좋아요 바지 정말 좋아서2개 더 구매했어요 이가격에 대박입니다. 바느질이 조금 ... |
| 3 | 2      | 선물용으로 빨리 받아서 전달했어야 하는 상품이었는데 머그컵만 와서 당황했습니다. 전... |
| 4 | 5      | 민트색상 예뻐요. 옆 손잡이는 거는 용도로도 사용되네요 ㅎㅎ                 |

```
df.tail()
```

|        | target | reviews                                           |
|--------|--------|---------------------------------------------------|
| 199995 | 2      | 장마라그런가!!! 달지않아요                                   |
| 199996 | 5      | 다이슨 케이스 구매했어요 다이슨 슈퍼소닉 드라이기 케이스 구매했어요가격 괜찮고 배송... |
| 199997 | 5      | 로드샵에서 사는것보다 세배 저렴하네요 ㅜㅜ 자주이용할께요                   |
| 199998 | 5      | 넘이쁘고 세련되보이네요~                                     |
| 199999 | 5      | 아직 사용해보지도않았고 다른 제품을 써본적이없어서 잘 모르겠지만 ㅎㅎ 배송은 빨랐습니다  |

- 결측치 X
- 데이터 타입 확인
  - target(rate): int, reviews: object

```
[ ] review_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200000 entries, 0 to 199999
Data columns (total 2 columns):
#   Column  Non-Null Count  Dtype  
---  -
0   rate    200000 non-null   int64  
1   review  200000 non-null   object  
dtypes: int64(1), object(1)
memory usage: 3.1+ MB
```

# #02 EDA + 전처리 - 1주차

## #1 EDA

- target(평점) 클래스 분포


- 1, 4 데이터 수 << 2, 5 데이터 수
- 부정, 긍정 감성값 비율 = 1:1

➡ 1, 2, 4, 5 클래스로 다중 분류 결정

↔

|        | count |
|--------|-------|
| target |       |
| 5      | 81177 |
| 2      | 63989 |
| 1      | 36048 |
| 4      | 18786 |

dtype: int64



# #02 EDA + 전처리 - 1주차

## #2 전처리

- 1) 텍스트 클렌징: 한글을 제외한 텍스트는 공백으로 변경
- 2) 불용어 제거: GIST 제공 불용어 사전 [stopwords-ko.txt](#) 사용
  - df 에서 추출해 본 불용어 리스트

```
count = Counter(word_list)
print(count.most_common(20)) # 가장 많이 나온 10개 출력
stopwords = ['이', '가', '은', '는', '을', '를', '의', '에', '도', '로', '과', '와',
             '하고', '인데', '해서', '으로', '그리고', '또', '좀', '더', '정말', '아주', '다', '요']
```

➡ 위의 리스트를 포함하면서 더 일반적인 불용어 사전 사용

# #02 EDA + 전처리 - 1주차

## #2 전처리

### 3) 토큰화 및 표제어 추출

- 토큰화: 온라인 리뷰에 적합하고 빠른 Okt tokenizer 사용



|   | target | lemmas_str                                        |
|---|--------|---------------------------------------------------|
| 0 | 5      | 배송 빠르다 굿                                          |
| 1 | 2      | 택배 엉망 이네 용 집 밑 층 말 도 없이 놔두다                       |
| 2 | 5      | 아주 좋다 바지 정말 좋다 개 더 구매 하다 가격 대박 이다 바느질 엉 성하다 편하... |
| 3 | 2      | 선물 용 빨리 받다 전달 하다 하다 상품 이다 머그컵 만 오다 당황 하다 전화하다 ... |
| 4 | 5      | 민트 색상 예쁘다 옆 손잡이 늘다 거 늘다 용 도로 도 사용 되다              |

### 4) 벡터화: train\_test\_split 데이터 분리 후 Vectorizer 적용

- 어떤 Vectorizer? ➡ 모델링 성능 측정을 위해 우선적으로 TfidfVectorizer 사용

# #03 모델링



# #03 모델링 - 2주차: 4가지 분류 모델 성능 평가

4가지 개별 분류 모델 선정: 로지스틱 회귀, SVM, XGBoost, 랜덤포레스트

- SVC, XGBoost 수행 시간 >> 코랩 런타임(12시간) 문제

| 모델      | 기본 파라미터 | 최적 파라미터 (튜닝 후) | 최적 파라미터                                                                    |
|---------|---------|----------------|----------------------------------------------------------------------------|
| 로지스틱 회귀 | 0.6652  | 0.6611         | 1. C = 0.8439...<br>2. penalty = 'l2'                                      |
| SVC     | -       | -              | -                                                                          |
| XGBoost | 0.64    | -              | -                                                                          |
| 랜덤포레스트  | 0.5738  | 0.5044         | 1. max_depth = 50<br>2. n_estimators = 500<br>3. class_weight = 'balanced' |

# #03 모델링 - 3주차: 분류 모델 추가, 개별 모델 성능 평가

런타임 문제로 유사한 분류 모델 추가 - SVC → LinearSVC, XGBoost → LightGBM

| 모델        | 기본 파라미터 | 최적 파라미터 (튜닝 후) | 최적 파라미터                                                                                          |
|-----------|---------|----------------|--------------------------------------------------------------------------------------------------|
| 로지스틱 회귀   | 0.6652  | 0.6611         | 1. C = 0.8439...<br>2. penalty = 'l2'                                                            |
| SVC       | 0.6670  | -              | -                                                                                                |
| LinearSVC | 0.6630  | 0.6625         | 1. C = 0.7052<br>2. loss = 'hinge'<br>3. tol = 0.0016<br>4. penalty = 'l2'<br>5. max_iter = 5000 |
| XGBoost   | 0.64    | -              | -                                                                                                |
| LightGBM  | 0.6097  | 0.6130         | -                                                                                                |
| 랜덤포레스트    | 0.5738  | 0.5044         | 1. max_depth = 50<br>2. n_estimators = 500<br>3. class_weight = 'balanced'                       |

# #03 모델링 - 3주차: 분류 모델 추가, 개별 모델 성능 평가

## PyCaret을 이용해 3만 개 데이터셋 샘플에 대해 분류 모델 성능 비교

**PyCaret** - 머신러닝 Workflow를 자동화하는 Python 기반 오픈소스 ML 라이브러리  
PyCaret.Classification.compare\_models 로 AutoML 실행

|          | Model                           | Accuracy | AUC    | Recall | Prec.  | F1     | Kappa  | MCC    | TT (Sec) |
|----------|---------------------------------|----------|--------|--------|--------|--------|--------|--------|----------|
| lr       | Logistic Regression             | 0.6330   | 0.0000 | 0.6330 | 0.5880 | 0.5878 | 0.4390 | 0.4507 | 39.8367  |
| lightgbm | Light Gradient Boosting Machine | 0.6219   | 0.8251 | 0.6219 | 0.5780 | 0.5823 | 0.4244 | 0.4341 | 28.6433  |
| svm      | SVM - Linear Kernel             | 0.6267   | 0.0000 | 0.6267 | 0.5563 | 0.5729 | 0.4234 | 0.4390 | 20.7367  |
| xgboost  | Extreme Gradient Boosting       | 0.6163   | 0.8187 | 0.6163 | 0.5746 | 0.5701 | 0.4129 | 0.4265 | 281.2000 |
| et       | Extra Trees Classifier          | 0.6220   | 0.8114 | 0.6220 | 0.5678 | 0.5613 | 0.4155 | 0.4341 | 128.8900 |
| rf       | Random Forest Classifier        | 0.6177   | 0.8112 | 0.6177 | 0.5629 | 0.5539 | 0.4071 | 0.4271 | 60.8967  |
| gbc      | Gradient Boosting Classifier    | 0.6028   | 0.0000 | 0.6028 | 0.5722 | 0.5486 | 0.3884 | 0.4074 | 466.6733 |
| ada      | Ada Boost Classifier            | 0.5913   | 0.0000 | 0.5913 | 0.5620 | 0.5381 | 0.3712 | 0.3891 | 47.4267  |
| dt       | Decision Tree Classifier        | 0.5238   | 0.6612 | 0.5238 | 0.5032 | 0.5118 | 0.2986 | 0.2995 | 25.3167  |
| knn      | K Neighbors Classifier          | 0.4338   | 0.6009 | 0.4338 | 0.3937 | 0.3617 | 0.0974 | 0.1179 | 141.3067 |
| nb       | Naive Bayes                     | 0.2626   | 0.5502 | 0.2626 | 0.4222 | 0.2744 | 0.0887 | 0.1047 | 7.5400   |
| dummy    | Dummy Classifier                | 0.4019   | 0.5000 | 0.4019 | 0.1615 | 0.2305 | 0.0000 | 0.0000 | 3.2367   |

➡ SGDClassifier 추가


# #03 모델링 - 4주차

모델 2차 추가 후, 최종 개별 모델 성능 비교

| 모델             | 기본 파라미터 | 최적 파라미터 (튜닝 후) |
|----------------|---------|----------------|
| 로지스틱 회귀        | 0.6652  | 0.6611         |
| SVC            | 0.6670  | -              |
| LinearSVC      | 0.6630  | 0.6625         |
| XGBoost        | 0.64    | -              |
| 랜덤포레스트         | 0.5738  | 0.5044         |
| SGD Classifier | 0.6351  | 0.6437         |
| CatBoost       | 0.6404  | 0.6391         |
| LightGBM       | 0.6097  | 0.6130         |

\*런타임 문제로 SVC는 제외

# #03 모델링 - 5주차 앙상블 보팅 모델 실험 + 언더샘플링 실험

| 유형     | 사용 모델          | 기본 파라미터 | 최적 파라미터<br>(튜닝 후) |                                                                                           |
|--------|----------------|---------|-------------------|-------------------------------------------------------------------------------------------|
| 소프트 보팅 | 로지스틱 회귀        | 0.6655  | 0.6633            |  성능 향상 |
|        | SGD Classifier |         |                   |                                                                                           |
| 하드 보팅  | 로지스틱 회귀        | 0.661   | 0.666             |                                                                                           |
|        | linear SVC     |         |                   |                                                                                           |
|        | SGD Classifier |         |                   |                                                                                           |
| 언더 샘플링 | 로지스틱 회귀        | 0.5     | -                 |                                                                                           |
|        | SVC            | 0.52    | -                 |                                                                                           |
|        | SGD Classifier | 0.55    | -                 |                                                                                           |

\*언더 샘플링은 train dataset으로 진행

\*linaer SVC : predict\_proba 지원 X

# #03 모델링 - 6주차

구글 코랩 Pro 구독 후 SVC 추가 보팅 & 오버샘플링 실험

| 유형     | 사용 모델          | 기본 파라미터 | 최적 파라미터 (튜닝 후) |
|--------|----------------|---------|----------------|
| 소프트 보팅 | 로지스틱 회귀        | 0.6633  | 0.6687         |
|        | SVC            |         |                |
|        | SGD Classifier |         |                |
| 하드 보팅  | 로지스틱 회귀        | 0.6680  | 0.6660         |
|        | SVC            |         |                |
|        | SGD Classifier |         |                |
| 오버 샘플링 | 로지스틱 회귀        | 0.5587  | 0.56           |
|        | SVC            | 0.6136  | -              |
|        | SGD Classifier | 0.63    | -              |

# #03 모델링 - 7주차

## 최종 모델 & 파이프라인

최종 모델로 CountVectorizer, TfidfVectorizer 비교 실험  
시간 상 파이프라인 전체 튜닝 → 개별 모델 튜닝 후 파이프라인 결합 방식 변화

| 벡터라이저 | 정확도    |
|-------|--------|
| Count | 0.6324 |
| Tfidf | 0.6638 |

✓ 최종 파이프라인

|                 |                                                                  |
|-----------------|------------------------------------------------------------------|
| TfidfVectorizer | <pre>max_df=0.7023255535070088 min_df=2 ngram_range=(1, 2)</pre> |
| 소프트보팅           | 로지스틱 회귀                                                          |
|                 | SVC(kernel='linear')                                             |
|                 | SGDClassifier                                                    |

데이콘 리더보드  
예상 순위 58위

# #04 프로젝트 리뷰



# #04 프로젝트 리뷰

## 프로젝트 보완점

|     |                                                                                                                                                           |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| 장서연 | 데이터셋 분할 방식을 프로젝트 진행 초반부터 하나로 통일하지 못한 점이 아쉬웠다. 개인별 성능 차이에 학습 데이터의 순서도 반영이 되었을 수도 있었겠다. 여러 사람이 분할해 모델을 돌리는 방식으로 프로젝트를 진행하다 보니 전체적으로 실험 과정에서 일관성이 부족했던 것 같다. |
| 고은비 | 구글 코랩 구독을 조금 더 빨리 결정 했으면 속도상에서의 여유가 조금 더 생겼을 것 같다. 리소스 문제로 생긴 한계점이 아쉬웠다.                                                                                  |
| 김태영 | 사용한 데이터셋이 크기가 큰 텍스트 타입이었기 때문에 시간 복잡도가 큰 모델을 튜닝하지 못하는 등 성능을 어느 정도 포기했어야 했다는 점이 아쉬웠다.                                                                       |
| 박린  | 그동안 교재에서 다루던 예제와는 달리 큰 크기의 데이터를 처음 다루다 보니, 미숙한 점이 있었던 것 같다. 이로 인해 모델링 결과를 내는 것에 시간을 지체한 점, 그리고 좋은 성능을 내는 모델보다는 런타임 내에 돌릴 수 있는 모델로 타협해야 했던 점이 아쉬웠다.        |

- ➡ 큰 데이터셋 + 제한된 리소스 환경 모델 → 모델 성능 타협
- ➡ 같은 데이터셋, 다른 분할 방식 → 실험 과정 일관성 부족

# THANK YOU

