




사용자의 일상 사진을 이해하는 멀티모달 AI

Multimodal VQA Task for Understanding User Images

목차

1. 과제 소개 / 문제 정의
2. 방법론
3. 실험 및 결과
4. 결론



1. 과제소개/문제정의



1. 과제 소개 / 문제 정의

주제 | 사용자의 일상 사진을 이해하는 멀티모달 AI 모델 개발



- 다양한 일상 사진들에 대해 선다형 질문이 주어지면 정답을 선택하는 AI 모델 개발

e.g., What time of day would it likely to be in 3 hours?

- Evening as the sun sets
- Morning when the sun is rising
- Afternoon with bright daylight
- Night under a dark sky ✓

1. 과제 소개 / 문제 정의

Baseline | BLIP2

- 사전학습된 Vision Encoder와 LLM을 사용
→ 비용/메모리  & 백본 교체 쉬움
- 중간에 Q-former만 학습, 시각-언어를 연결

대회 규칙

- 추론에 사용되는 모든 모델의 총 파라미터 수 합계는 3B 미만이어야 함
- 다음 중 최소 하나의 경량화 기법을 사용해야 함;
→ Image Encoder or LLM 경량화 / Q-former 토큰 수 또는 transformer layer 수 감소 / 양자화 / 파라미터 공유 등
- 사전학습 모델 사용 시 2024년 이전 공식 가중치 공개 모델만 가능
- API 기반 모델 사용 불가 (e.g., OpenAI API, Gemini API)
- 2025년 6월 11일 이전 공식적으로 공개되었으며 라이선스가 있는 외부 데이터셋 사용 가능

2. 방법론



2. 방법론

2.1 Dataset

- 문제에 적합한 데이터셋
- 데이터셋 후보
- 최종 데이터셋

2.2 Method

- 모델
- LoRA
- 양자화
- 지식 증류

2.1 데이터셋 – 문제에 적합한 데이터셋

데이터셋의 중요성

- 모델 일반화와 상한선 결정: 문항 난이도·편향·주제 분포가 성능을 좌우.
- 태스크 정합성: 4지선다 MC-QA 형식 여부가 파이프라인 복잡도와 직결.
- 라이선스/재현성: 공개 검증 가능해야 실험 재현·배포가 용이.
- 엔지니어링 용이성: 공통 포맷 통일.

대회에서 정의한 데이터셋

- 포맷: 단일 .csv에 이미지 경로, 질문, 보기 4개, 정답이 포함.
- 채점: 4지선다 정확도.
- 제약: 실사 이미지 기반, 오답·정답 포맷 일관성 필요.

2.1 데이터셋 – 문제에 적합한 데이터셋

우리가 찾고자 한 데이터셋

- 바로 사용 가능한 4지선다(MC) 포맷 또는 변환이 쉬운 실사 이미지 VQA.
- 일상 장면 중심(도메인 근접), 질문 유형 다양, 난이도 분포 적절.
- 라이선스가 명확하고, 공개 다운로드 가능.
- 대용량은 최소한으로 샘플링하며 정합성이 우선.

2.1 데이터셋 – 데이터셋 후보

Visual7W-Telling

- 포맷: 4지선다, COCO 서브셋, 7W 유형 다양.
- 특징: 변환 불필요, 도메인 근접.

A-OKVQA

- 포맷: 4지선다 + rationale, COCO 2017.
- 특징: 상식·배경지식 요구 문항으로 지식 추론 강화.

VQA_{v2}

- 포맷: Open-Ended 단답.
- 특징: 4지선다로 변환 필요, 작업량 큼



Q: What endangered animal is featured on the truck?

A: A bald eagle.

A: A sparrow.

A: A humming bird.

A: A raven.

Visual7W



Q: What was the name of the first cloned type of this animal?

A: Dolly

Knowledge base

A-OKVQA

2.1 데이터셋 – 데이터셋 후보

VCR

- 포맷: 4지선다(+Rationale), 영화 스틸 도메인.
- 특징: 라이선스 비상업, 도메인 차이 존재.

Synthetic VQA–NLE (GQA 기반)

- 포맷: 단답+설명, 합성 생성물 포함.
- 특징: MC 변환 필요, 스타일 격차.

DiffusionDB / TrueFake 합성 데이터셋

- 장점: 대량 증강 가능, 잡음·압축 내성 향상.
- 특징: 대규모 정제 필요, 대회 도메인과 비슷함.



DiffusionDB

2.1 데이터셋 – 최종 데이터셋

Visual7W-Telling

구성

- 이미지 $\approx$ 47k(COCO), QA $\approx$ 328k, 7W 유형, Telling(4지선다) 사용.

채택 이유:

- MC 포맷 완비로 변환 불필요, 일상·실사 도메인에 근접, 질문 유형 다양.

사용 방식:

- 공통 CSV 스키마로 변환: id, image_path, question, choice_a~d, answer
- 선택지 A-D 무작위 셔플로 포지션 편향 제거
- UID 생성(img_path|question|A|B|C|D 해시)로 Teacher-logit 캐시 정합성 보장

2.1 데이터셋 – 최종 데이터셋

A-OKVQA

구성:

- 질문 $\approx$ 25k, COCO 2017, 4지선다 + rationale.

채택 이유:

- 상식/배경지식 요구 $\rightarrow$ 지식 추론 보강, Visual7W와 도메인 호환.


사용 방식:

- 공통 CSV 스키마로 변환, rationale은 보조 신호로 별도 보관
- 동일한 선택지 셔플·UID 규칙 적용

2.2 Method

1. 모델

- BLIP-2
 - Vision Encoder❄️ + Q-Former🔥 + LLM❄️
- 선정 이유
 - 2024년 전 가중치 공개 / 비상업적 이용 / 오픈소스 라이선스로 배포 / 3B
 - 멀티모달 / VQA task



2.2 Method

2. PEFT – LoRA

- PEFT : Parameter-Efficient Fine-Tuning
- LoRA : Low-Rank Adaptation of Large Language Models
 - 파라미터의 변화량(ΔW)만 저차원 행렬(Low-Rank Matrices)로 근사해서 학습
 - 기존 가중치 (W) 고정 + 추가된 작은 행렬만 학습 ($\Delta W=AB$)
 - 전체 layer를 LoRA 기법으로 학습

$$y = Wx \qquad W' = W + \Delta W \qquad \Delta W = AB$$

- 효과 : 학습해야 하는 매개변수가 적어서 학습이 빠름

2.2 Method


3. 양자화(quantization) (시도)

- 값을 다룰 때, 8bit 또는 4bit 등 작은 bit 단위로 표현하는 방식
 - GPU 메모리 크게 절감 → 학습 중 GPU 메모리 부족 문제 완화
- 양자화 대상
 - 모델 가중치 양자화
 - 옵티마이저 양자화
- 사용하지 않은 이유
 - 파라미터 수 자체가 줄어드는 것 X
 - 성능 저하의 위험이 있음

2.2 Method

4. 지식 증류 (Knowledge Distillation) (시도)

- 큰 모델(Teacher)이 학습한 지식을 작은 모델(Student)에 전달하는 기법
- Student model은 Teacher Model의 soft target을 활용하여 학습
 - hard label = 일반적으로 사용하는 정답 label (0,1)
 - soft label = Teacher Model의 예측 확률 분포 → 더 풍부한 정보 전달
 - $\text{Loss} = \text{Hard label loss} + \text{Soft label loss}$



2.2 Method

4. 지식 증류 (Knowledge Distillation) (시도)

- 큰 모델(Teacher)이 학습한 지식을 작은 모델(Student)에 전달하는 기법
- 사용하지 않은 이유
 - Teacher Model로 사용하고자 했던 모델의 성능이 40%로,
 - 학습 추이는 양호했으나, 리소스 및 시간의 제약으로 인해 지속적인 학습 X
 - Student Model로 지식증류 시도했으나 유의미한 결과X

3. 실험 및 결과



3. 실험 및 결과

1. 데이터 전처리

- 데이터셋 | Visual7W
- 데이터 전처리
 - Position Bias 제거
: 각 샘플의 보기 A-D를 무작위 셔플, 정답 인덱스를 새 위치에 맞게 매핑
 - Data Split
: 정답 분포 유지(stratify)로 Train 90%, Val 10%

3. 실험 및 결과

2. 사전학습 모델

- Processor | blip2-opt-2.7b (이미지 사이즈 224*224)
- Vision Encoder | clip-vit-large-patch14, clip-vit-base-patch16
- LLM | faln-t5-large, opt-2.7b

3. Loss & Optimizer

- Loss | CrossEntropyLoss(공통), $\text{KLDiv} \times T^2$ (KD 실험만 해당)
- Optimizer | AdamW
- Additional Params | weight decay = 0.01

learning rate = 고정 or 파라미터 그룹 별 차등학습

3. 실험 및 결과

4. 모델 입력

- [Q-Former 쿼리 임베딩] + [텍스트 임베딩] concat
- 추가로 텍스트·이미지 특징 벡터를

Concat + Element-wise Product + Absolute Difference로 결합하기도 함

5. Classification Head

- $2048 \rightarrow 512 \rightarrow 256 \rightarrow 4$
- $1024 \rightarrow 512 \rightarrow 4$

위와 같은 projection 옵션으로 classification head를 구성
classification head 없이 실험을 진행하기도 함

3. 실험 및 결과

6.1. KD(Teacher-Student) 모델 - 실험 결과

- Teacher 모델 | Accuracy 35-40% (리소스 부족으로 학습 멈춰 성능 추가 개선 여지 있음)
- Student 모델 | Train Accuracy $\approx$ 25%, Validation Accuracy = 24.98% (4지선다 랜덤선택 수준)
→ Teacher 모델에서 달성한 일정 성능이 Student에 전혀 전이되지 않았음

한계/원인

- Teacher 모델의 추가 성능 개선을 진행하지 못함
- Student 본체(LLM/ViT)는 완전 동결 상태에서 Q-Former·투영·헤드만 학습
→ 텍스트 프롬프트와 이미지 간 상호작용이 분류 헤드의 마지막 토큰 표현에 충분히 반영되지 못했을 가능성이 있음

3. 실험 및 결과

6.2. Student 모델 단독 - 1차 실험 결과

- Accuracy $\approx$ 25% 정체 (4지선다 랜덤 선택 수준)
- Loss = 1.38 부근에서 진동 $\approx \ln(4) = 1.386$
→ 즉, 유의미한 학습이 일어나지 않음


한계/원인

- 패딩 방향 오류
: 오른쪽 패딩을 써서 마지막 토큰/레이블 정렬 깨짐, [PAD]를 풀링·예측하게 되어 학습이 무너짐

3. 실험 및 결과

6.3. Student 모델 단독 - 2차 실험 결과 (최종)

- Validation Accuracy 최대 78% / Test Accuracy 68%
- Train Loss = 0.02 수준까지 감소
→ 1차 실험의 패딩 문제를 해결해 유의미한 학습에 성공



3. 실험 및 결과

6.3. Student 모델 단독 - 2차 실험 결과 (최종)

- Validation Accuracy 최대 78% / Test Accuracy 68%
- Train Loss = 0.02 수준까지 감소
→ 1차 실험의 패딩 문제를 해결해 유의미한 학습에 성공

실험 상세

- 데이터셋 | Visual7W 중 1000개 샘플링 (적은 데이터로 높은 accuracy와 generalization 성능 달성, 추가 리소스 환경에서 더 높은 성능 달성 가능할 것)
- 모델 | blip2-opt-2.7b, w/o freeze
- 전체 레이어에 LoRA 적용, 양자화 X
- 왼쪽 패딩 적용; 오른쪽 패딩은 높은 확률로 의미 없는 값일 확률을 고려해야 함을 알 수 있었음

4. 결론



4. 결론

일상사진 특화 4지선다 VQA

1. 데이터셋 탐색 및 구축

- 다양한 4지선다 VQA 데이터셋 조사
- 일반 VQA → 4지선다 변환 시도
- 대회 도메인과 한 합성 데이터셋 탐색

2. 모델 학습 기법

- LoRA, 양자화(Quantization), 지식증류(Knowledge Distillation) 적용 실험

3. 성능 저하 원인 분석 → 해결

- 입력 시 왼쪽 패딩(left padding) 적용 → 학습 안정화 및 성능 향상

4. 결론

일상사진 특화 4지선다 VQA

4. 한계 및 발전 가능성

- 시간·리소스 제약으로 지식증류 완전 구현에 실패
- 다양한 옵션 조합을 체계적으로 실험하지 못함
- 향후 하이퍼파라미터 및 구조 최적화 여지 존재

감사합니다

