



Euron9th 프로젝트 발표

ML 팀





설문조사 데이터로 1인당 소비 수준과 빈곤율 예측

DataForGood 팀

팀원: 이시현, 권혜수, 엄지민, 조한희

프로젝트 설명



1. 공모전 주제 및 목표

< DRIVENDATA 빈곤율 예측 공모전 참여 >

DRIVENDATA

DEVELOPMENT

Poverty Prediction Challenge

Estimate individual and aggregate household consumption from limited survey data.



\$10,000 in prizes



Completed Feb 2026



1,322 joined

DRIVENDATA?

- 사회문제를 해결하는 국제 데이터사이언스 공모전 플랫폼
- 총 488팀 참여

1. 공모전 주제 및 목표

1인당 소비 수준을 예측하여 빈곤율을 추정

1. 익명화된 설문조사 데이터를 활용해, 설문조사 간 결측을 보완하는 모델을 개발
2. 모델 기반으로 1인당 가구 소비 수준을 예측
3. 소비수준으로 빈곤율을 추정
 - feature(가구 특징)으로 소비 수준(cons_ppp17)과의 관계를 학습
 - 이후 새로운 feature data만으로 cons_ppp17와 threshold별 빈곤율을 계산

survey_id	hhid	cons_ppp17
100000	100001	25.258402
100000	100002	16.996706
100000	100003	13.671848
100000	100004	7.1894746
100000	100005	10.200055



survey_id	pct_hh_below_3.17	pct_hh_below_3.94	pct_hh_belo
100000	0.06736375236	0.118927155	0.16990
200000	0.05932569096	0.1115603981	0.15900
300000	0.04980335691	0.1003810796	0.14950

프로젝트 과정





계획 수립

1주차	데이터 분석(EDA) 및 데이터 전처리 방안 역할 분배
2주차	데이터 전처리 방안 통합: 인코딩, 결측치, 범주형 변수 처리
3주차	피처 엔지니어링
4주차	피처 통합 지수 생성 · 방식 통일
5주차	Rate 개선
6주차	Cat feature 활용 실험 및 조합 비교 -> 최종 제출

2. 데이터 전처리 과정

1/2주차: EDA, 데이터 분석, 인코딩, 결측치 처리



- 변수 유형 및 결측치 처리: 교육 수준 → 라벨 인코딩, 수치형 → mean 처리 등
- 소비수준 예측 데이터와 빈곤율 예측 데이터로 나누어 역할 분담 후 **LightGBM**으로 피처 처리 비교
- 타겟과의 상관관계 시각화, 영향력이 큰 피처 분석 등 **EDA** 수행
 - 변수 **이상값** 확인 ex. 비율 값을 나타내야 하는 피처에 1보다 큰 value 다수
 - 중요한 피처와 중요하지 않은 피처에 가중치 부여

2. 데이터 전처리 과정

3주차: Feature Engineering

1. 식량 안보 및 영양 (Food Security)
 - a. HDDS(가정 식단 다양성 점수) 12개 식품군 몇 종류 먹었는지 단순 합계
 - b. Modified FCS(수정된 식량 소비점수) 식품군 섭취 여부 x 영양 가중치
 - c. Protein Rich Flag(단백질 섭취 여부): 육류나 유제품을 하나라도 먹었으면 1, 아니면 0
2. **V 생활 환경 및 인프라** (Living Standards): PCA 활용하여 관련 피쳐들 압축
3. **V 인구 구조 및 부양** (Demographics): (아동 + 노인 수) ÷ (성인 남녀)
4. **V 경제적 잠재력** (Economic Capacity): Economic Potential Index (경제 잠재력 지수)
 - o educ_max(교육) + log(utl_exp)(공과금 지출력) + owner(자가 보유).
5. CatBoost의 cat_features 활용 - 범주형 변수 처리에 최적화된 파라미터 → 성능 차이가 없어 제외

⇒ GBM 계열 안에서 모델 실험하며 **최적의 피쳐 도출**

3. 소비수준 & 빈곤율 예측 모델

4주차: Feature 통합 지수 생성 · 방식 통일

3. 빈곤율 계산 CDF 방식 적용 실험

- CDF: 누적분포함수 (Cumulative Distribution Function),
확률 변수 X 가 특정 값 x 보다 작거나 같을 확률 $P(X \leq x)$ 를 나타내는 함수
- Rate는 CDF 방식으로 통일

$$F(x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

4. 시그마(sigma) 최적화

- sigma: 표준편차, 분포의 퍼짐 정도 결정
시그마가 클수록 CDF 그래프의 기울기가 완만하고 작을수록 가파르게 상승한다

```
z = (logz[None, :] - mu[:, None]) / (sigma + 1e-12)

# log-space CDF# P(cons < z) = Phi((log(z) - mu_log) / sigma_log)
probs = norm.cdf((logz[None, :] - mu[:, None]) / (sigma + 1e-12))
rates = np.average(probs, weights=w, axis=0)
```

3. 소비수준 & 빈곤율 예측 모델

4주차: Feature 통합 지수 생성 · 방식 통일

1. FCS (식료품 소비 지표) 통일

- consumedXXX 식료품 구매 여부 피처를 통합하는 지수 생성 실험
- 관련 도메인 스터디 및 논문 참고
- 식품군별 분류 및 가중치 부여

2. 모델 실험

- CatBoost 단일보다 여러 모델 조합 + 앙상블로 성능 확인
- 최종 반영: LGB + XGB + CAT -> Stacking (ElasticNet)

```
# base models: LightGBM + XGBoost + CatBoost# meta model : ElasticNetCV (stacking)
P_va = np.vstack([pred_lgb_va, pred_xgb_va, pred_cat_va]).T
meta.fit(P_tr, y_tr)
pred_meta_va = meta.predict(P_va)
```


3. 소비수준 & 빈곤율 예측 모델

5주차: Rate 개선 및 calibration 제거

1. 빈곤율 계산 방식 실험 CDF vs MI vs Parametric 중 MI


- MI(Monotonic Interpolation) 방식 이 가장 좋은 성능
: 분포 가정 없이, 예측값의 순서를 믿고 단조로 rate를 맞추는 방식

2. Rate 최적화를 위한 calibration 실험

- CDF 그래프의 기울기 보정을 위한 calibration 적용
- 결과, 오히려 성능 저하로 제거 결정
- 최종 rate는 CDF 기반 으로 계산

예측이 threshold에 대해 단조(monotone)하도록 Isotonic Regression(단조 보정) 적용

* 독립 변수(X)가 증가할 때 종속 변수(Y)도 같거나 커져야 한다는 제약



```
# monotone fix (threshold가 커질수록 rate는 증가해야 함)
ir = IsotonicRegression(increasing=True, out_of_bounds="clip")
fixed = ir.fit_transform(np.arange(len(arr)), arr)
```

3. 소비수준 & 빈곤율 예측 모델

5주차: Rate 개선 및 calibration 제거

3. global sigma vs per-survey sigma

- sigma: 표준편차, 분포의 퍼짐 정도 결정
- 3개의 survey id에 따른 개별 시그마 적용 VS 단순 global 시그마 적용
- 최종 반영

: survey 별 시그마를 직접 추정하는 방식 대신, survey 요약 통계로 시그마를 예측하여 적용

```
# survey별 mu 요약통계 → sigma 모델 학습 → test sigma_hat 생성
feat_train = make_survey_features_from_logmu(train_eval, "oof_logmu", survey_col)
sigma_model.fit(X_sig, y_sig)

feat_test["sigma_hat"] = sigma_model.predict(feat_test.drop(columns=[survey_col]))
```

3. 소비수준 & 빈곤율 예측 모델

6주차: cat feature 및 조합 비교

1. cat feature 활용 실험

- cat feature를 부분만 넣으면 효과가 약했음
실험을 통해 전체 성능 개선 시도
- 최종 반영
: 범주형을 원핫 인코딩으로 확장, object 형 결측을 CatBoost 호환되게 처리
- 효과
: 범주형 정보 손실을 줄이고 결측 처리

2. 제출

```
df = pd.get_dummies(df, columns=multi_cols, drop_first=False)for col in df.select_dtypes(include=['object']).columns:  
    df[col] = df[col].astype(str).replace('nan', 'Missing_Category')
```

프로젝트 결과



4. 최종 파이프라인

Step 1 Feature Engineering

- 가구원수 불일치 수정(hsize_fixed)
- 농업/어업 플래그(is_agri_fish)
- binary 통일 + label/one-hot
- survey별 중앙값 결측 대체
- Asset PCA(wealth index) 생성
- 인구구조 파생변수(부양비, child_share)
- 여성 가장 피처 추가
- utl_exp_ppp17 공과금 피처 log화 및 clipping
- weight 피처 clipping
- sworkersh, num_children5, survey_id, num_adult_~ 피처 삭제

Step 2 Consumption 예측

Step 3 Sigma 추정

Step 4 Poverty Rate 산출

Step 5 제출물 생성

4. 최종 파이프라인

Step 1

Feature Engineering

Step 2

Consumption 예측

- LGB + XGB + CAT (GroupKFold by survey_id)
- ElasticNet 메타모델로 OOF/test log(cons) 생성

Step 3

Sigma 추정

- survey 요약통계로 sigma 모델 학습 → test sigma_hat 생성

Step 4

Poverty Rate 산출

- log-space CDF로 threshold별 빈곤율 계산
- 단조성 보정(Isotonic)

Step 5

제출물 생성

1. household: exp(test_logmu)로 cons 생성: 소비 예측
2. rate: survey별 threshold 컬럼 정렬 + zip 패키징 빈곤율 예측

5. 성능 결과

#1 모델 학습 및 검증

- Threshold 개수: 19개
- 모델 구조:
 - Base: LightGBM + XGBoost + CatBoost
 - Meta: ElasticNet (Stacking)
- 검증 방식: GroupKFold (survey 단위, 3 folds)
- **Fold별 log RMSE (meta model)**
 - Fold 1: **0.3338**
 - Fold 2: **0.3348**
 - Fold 3: **0.3366**

⇒ Fold 간 성능 편차가 작아 모델 안정성 확보

5. 성능 결과

#2 빈곤율(rate) 예측 결과

- 방식:
 - $\log(\text{consumption})$ 예측값 기반
 - CDF 방식 + survey-level sigma 모델링
- 결과:
 - 모든 survey에서 threshold 증가에 따라 빈곤율이 단조 증가
 - survey 간 분포 차이는 유지되면서, 비정상적인 굴곡 없이 매끄러운 누적분포 형성

#3 최종 제출 성능 (Private LB)

- **Best Private Score: 14.552**
 - 내부적으로 survey별 빈곤율(rate) 예측 오차를 종합한 값, 대회 공식 평가 점수 (낮을수록 좋음)
- **wS-wMAPE: 11.256**
 - Weighted Survey-wise Mean Absolute Percentage Error
 - survey 단위로 threshold별 빈곤율 예측 오차를 가중 평균한 MAPE (오차)

6. 대회 최종 결과

DEVELOPMENT

Poverty Prediction Challenge

Estimate individual and aggregate household consumption from limited survey data.

 **\$10,000** in prizes

 **Completed** Feb 2026

 **1,322** joined

#76



DataForGood
4d 13h ago · 1 submission

14.552 11.256



AP.SIGNAL:

이미지 콘텐츠의 활용도 분석 및 성과 예측 AI Agent

EWHA-RYSH | 조승연, 김두현, 노현선, 박혜린

2026 AMORE PACIFIC AI INNOVATION CHALLENGE


[브랜드 콘텐츠 모니터링] 부분 참여

“글로벌 마케팅의 문제는 콘텐츠가 아니라, 콘텐츠를 판단하는 기준이다.”
다양한 콘텐츠 속에서 어떤 콘텐츠가 어떤 국가에서 성과를 내는지는 설명되지 않는 상황

AP.SIGNAL

아모레퍼시픽 인스타그램 계정 속 이미지 콘텐츠 활용도 분석 및 성과 예측 AI Agent
국가별 콘텐츠와 성과 데이터를 기반으로 이미지 유형별 활용도 & 소비자 반응 정량화

AP.SIGNAL



1. 콘텐츠 활용도 모니터링: 각 국가 인스타그램 계정에서 어떤 이미지 유형이 반복적으로 사용되고 있는지를 분류·집계
2. 콘텐츠 성과 분석: 이미지 유형별 좋아요·댓글 등 소비자 반응 지표를 비교 분석하여 실제로 성과가 나는 콘텐츠를 구분
3. 고성과 패턴 도출: 국가별로 상위 성과 콘텐츠가 집중되는 이미지 유형과 패턴을 도출
4. 신규 콘텐츠 성과 예측: 게시 전 콘텐츠의 이미지 유형과 특징을 기반으로 해당 국가에서의 상대적 성과 수준을 사전에 예측

데이터 수집 및 전처리


Step 1. Apify를 이용해 LANEIGE의 국가별 인스타그램의 게시물 100개 수집

*대상 7개국: 싱가포르, 인도네시아, 필리핀, 베트남, 일본, 말레이시아, 태국

Step 2. 이미지 파일, 소비자 반응 정보(좋아요·댓글·참여율), 이미지 유형을 하나의 데이터셋으로 정리

*로그 변환 및 정규화를 거쳐 극단값의 영향을 줄이고 분포를 일정하게 맞춤으로써 국가 간 비교 가능하게 함

likes	comments	engagement	post_date	main_type	image_type_aux
30	0		30 251225	1	texture_focus
43	1		44 251225	1	collection_view
12	0		12 251224	3	shape_focus
28	0		28 251223	1	texture_focus
7	0		7 251222	1	collection_view
19	0		19 251221	1	collection_view
18	0		18 251220	1	collection_view
30	0		30 251219	1	
24	0		24 251218	1	
14	0		14 251217	1	
7	1		8 251216	7	
254	2	256	251211	1	collection_view



Exploratory Data Analysis

1. 이미지 타입별 활용 분포

- 이미지 타입별 게시물 개수 및 사용 비중 산출하고 가장 많이/적게 사용된 타입과 그 비중 확인

2. 이미지 타입별 성과 요약

- 타입별 평균/중앙값 참여율을 계산해 어떤 이미지 타입이 반응(참여율) 면에서 가장 효율적인지 정량적으로 비교

3. 고성과 분석 (Top 10% / 30%)

- 참여율 기준 상위 10%·30% 구간을 정의하고 각 타입이 대박(Top 10/30%)을 낼 확률과 집중도를 분석

4. 안정성 및 변동성 분석

- 타입별 참여율 분포의 변동성(표준편차, IQR, 평균 대비 상대 변동성)을 계산해 안정적인 타입 vs 변동성이 큰 타입 구분

5. 활용도 vs 성과 매트릭스

- 각 타입의 활용 비중, 평균 참여율, 상위 10% 진입 확률을 표준화해 과소 활용(확대 후보) / 과대 활용(축소·개선 후보) 타입 도출

6. 반응 성격 분석

- 타입별 댓글 비율(평균/중앙값)과 평균 좋아요/댓글을 통해 좋아요 위주 vs 댓글이 많이 달리는 깊은 반응 포맷 구분

Streamlit Dashboard

앞서 정의한 EDA 지표를 바탕으로 Streamlit 기반 대시보드 구현 — 국가·이미지 타입별로 상시 모니터링



<https://ap-signal-2026.streamlit.app>

Tab 1: 콘텐츠 활용도 모니터링

- 이미지 유형 활용도
- 소비자 참여율 분포

Tab 2: 성과 분석

- 성과 비교 및 반응 성격
- 고성과 분석
- 안정성 분석
- 전략 인사이트

Tab 3: 신규 콘텐츠 성과 예측

① 콘텐츠 활용도 모니터링

— 활용 분포 섹션

1. 분석 대상 국가 선택
2. 가장 많이/적게 사용된 이미지 타입
3. 활용 분포 그래프: 콘텐츠를 이미지 타입별로 분류해 각 비중 확인
4. 국가별 인사이트: 마케팅 전략 요약 및 분석

활용도 모니터링

이미지 유형별 활용 빈도와 좋아요·댓글·참여율 분포를

분석 대상

인도네시아

인도네시아

일본

말레이시아

필리핀

활용 분포

참여율 분포

가장 많이 사용된 타입

제품 단체샷

Type 1 - 전체의 25.0%


가장 적게 사용된 타입

제품 모델 단체샷

Type 6 - 전체의 2.0%

활용 분포

국가 계정에서 게시된 콘텐츠를 이미지 유형별로 분류하여, 각 이미지 타입이 전체 콘텐츠에서 차지하는 사용 비중을 확인합니다.



국가별 인사이트

전략 요약:

제품 정보와 분위기 연출을 병행하는 균형 지향적 이미지 전략

분석

제품 중심 이미지(Type 1-2)와 모델-연출 이미지(Type 3-4)가 비교적 고르게 활용되어, 특정 유형에 대한 편중이 크지 않습니다.

③ 성과 분석 — 성과 비교·반응 성격 섹션

좋아요·댓글 분포

이미지 타입별 좋아요와 댓글 수의 분포를 비교하여, 각 유형의 절대적 반응 규모와 분산 정도를 파악합니다.

좋아요와 댓글이 동시에 증가하는 콘텐츠가 존재합니다. 반응의 양과 질이 함께 확대되는 확산형 반응 메커니즘이 작동합니다.



활용도 vs 성과 분석

각 이미지 유형의 활용 비중과 실제 성과를 비교하여 운영 효율성을 분석합니다.

안정적 성과 예측은 가능하나, 현재의 제품 위주 방식은 고성능과 잠재력을 가진 모델 콘텐츠 효율을 낭비하는 구조.



1. 이미지 타입별 좋아요와 댓글 수의 분포 비교 각 유형의 절대적 반응 규모와 분산 정도를 파악
2. 각 이미지 유형의 활용 비중과 실제 성과를 비교하여 운영 효율성을 분석


② 콘텐츠 활용도 모니터링

— 참여율 분포 섹션

1. 분석 대상 국가 선택
2. 참여율 최고 타입
3. 참여율 분포 그래프: 콘텐츠를 이미지 타입별로 분류해 각 비중 확인
4. 국가별 인사이트: 마케팅 전략 요약 및 분석

참여율 분포

이미지 타입별 참여율의 분포를 비교하고, 유형별 반응 수준과 변동 폭을 함께 확인합니다.



참여율 최고 타입

제품+모델

Type 4 · 참여율: 0.0049

국가별 인사이트

이미지 타입별 참여율 분포: Type 3과 4에서 참여율 중앙값이 다른 타입보다 높게 형성되어 있으며, 분포 폭은 중간 수준을 유지합니다.

좋아요·댓글 수 분포: 좋아요와 댓글 모두 Type 4에서 극단적으로 높은 상위 값이 집중되며, 나머지 타입은 상대적으로 낮은 범위에 분포합니다.

👉 AI 해석 요약: 인도네시아 시장은 Type 4에서 반응이 집중적으로 발생하고 있으며, 타입별 반응 편차가 비교적 큰 상태입니다.

④ 성과 분석 — 고성과 분석

고성과 달성 가능성

각 이미지 유형이 상위 10% 및 30% 성과를 달성할 확률과 상위 성과 내에서의 집중도를 확인하여, 고성과 달성 가능성이 높은 콘텐츠 유형을 파악합니다.

Top 10%

달성 확률 최고
제품 단독샷
18.2%

Type 2 · 전체 게시물 중 상위 10% 성과 달성 확률

집중도 최고
제품 단체샷
40.0%

Type 1 · 상위 10% 성과 내에서 차지하는 비율

Top 30%

달성 확률 최고
제품 모델 단체샷
50.0%


Type 6 · 전체 게시물 중 상위 30% 성과 달성 확률

집중도 최고
제품 단독샷
26.7%

Type 2 · 상위 30% 성과 내에서 차지하는 비율

Top 10% vs Top 30% 달성 확률 비교

각 이미지 유형이 상위 10%와 30% 성과 구간에 진입할 확률을 비교하여, 고성과 달성 가능성의 차이를 확인합니다.



패턴 요약

소수 이미지 타입(Type 4)이 고성과를 독점적으로 만들어내는 구조

고성과 분포 특성으로 보기

Top 10% 성과가 전체 분포에서 매우 큰 비중을 차지합니다. 상위 성과와 중위권 성과 간 격차가 큼.

고성과 이미지 타입 집중도로 보기

Type 4에 고성과 콘텐츠가 강하게 집중되어 있습니다. 해당 타입이 Top 10%~30% 성과 구간을 동시에 형성합니다.

- 각 이미지 유형이 상위 10%/30% 성과를 달성할 확률과 상위 성과 내에서의 집중도 확인: 고성과 달성 가능성이 높은 콘텐츠 유형 파악
- 각 이미지 유형이 상위 10%/30% 성과 구간에 진입할 확률 비교: 고성과 달성 가능성의 차이 확인

⑤ 성과 분석 — 안정성 분석

성과 안정성 분석

표준편차(STD), IQR(사분위수 범위), 변동계수(CV)를 통해 이미지 타입별 성과의 변동성과 안정성을 측정합니다.



INSIGHT

성과 변동 폭이 큰 **고변동형**

— 성과 안정성 구조 및 지표 해석

- STD·IQR이 모두 높게 형성
- CV 역시 커, 평균 대비 변동성이 큰 구조

표준편차 (STD)

성과 변동성 측정



IQR (사분위수 범위)

중간 50% 퍼짐 정도



변동계수 (CV)

상대적 변동성



1. 표준편차, 사분위수 범위, 변동계수 계산
— 이미지 타입별 성과 변동성 및 안정성 측정 및 해석
2. 안정성 인사이트 제공

⑥ 성과 분석 — 전략 인사이트

종합 인사이트

선택된 국가의 콘텐츠 운영 현황과 성과 핵심을 종합적으로 요약합니다.

📍 **안정적 시장이나 모델 콘텐츠 활용 부족 → 확장 여지 큼**



현황

47%

제품 중심(유형1,2) 47%



성과 핵심

1.5~2배

유형4 반응을 1.5~2배로 독보적

활용도 vs 성과 분석

각 이미지 유형의 활용 비중과 실제 성과를 비교하여 운영 효율성을 분석합니다.



활용 현황

제품 중심(유형 1, 2)이 약 47%로 전체 운영의 중심을 담당.



실제 성과

유형4가 타 유형 대비 1.5~2배 높은 독보적인 반응률 기록, 나머지 유형은 변동폭 작고 폭발력 제한적.



비교 분석

안정적 성과 예측은 가능하나, 현재의 제품 위주 방식은 고성능 잠재력을 가진 모델 콘텐츠 효율을 낭비하는 구조.

콘텐츠 유형별 전략 제안

선택된 국가에서, 활용 비중 대비 성과가 과대/과소 평가된 콘텐츠 유형을 기준으로 운영 전략을 제안합니다.

과소 활용 타입

활용 비중은 낮지만, 참여율-상위 10% 진입 확률이 높아 추가 투입 시 성과 확장이 기대되는 유형입니다.

유형 4 · 제품+모델

- 활용도: 20.0%
- 성과 근거: 평균 참여율 0.0049 / Top10% 진입 확률 10.0%
- 해석: 타 유형 대비 약 2배 높은 반응률을 보이고 있어 활용 비중 확대가 필요한 유형

과대 활용 타입

운영 비중은 높으나, 성과 지표가 이를 따라가지 못해 투입 대비 효율이 낮은 유형입니다.

유형 1 · 제품 단체샷

- 활용도: 25.0%
- 성과 근거: Top10% 진입 확률 16.0%
- 해석: 높은 활용 비중을 차지하고 있으나 고성능과 이어지는 폭발력이 부족한 유형

유형 2 · 제품 단독샷

- 활용도: 22.0%
- 성과 근거: Top10% 진입 확률 18.2%
- 해석: 물량 대비 성과 효율이 낮아 점진적 축소 필요

⑦ 신규 콘텐츠 성과 예측: 게시 전 콘텐츠 성과를 예측하여 최적의 콘텐츠 전략 수립

AI 예측

게시 전 콘텐츠 성과를 예측하여 최적의 콘텐츠 전략을 수립할 수 있습니다.

분석 대상

인도네시아

이미지 업로드

Drag and drop file here
Limit 200MB per file · JPG, JPEG, PNG

Browse files

KakaoTalk_Photo_2026-01-04-18... 12.9KB



예측 성과

97.0%

높음

이미지 타입

Type 5 · 제품 없이 모델 중심으로 연출된 이미지

이 이미지는 ID 시장 내 전체 콘텐츠 대비 **높음** 수준의 상대적 성과 위치에 해당합니다.

1. 분석 대상 국가 선택
2. 성과를 예측하고자 하는 이미지 파일 업로드
3. 예측 성과 퍼센테이지 + 높음/보통/낮음 라벨 분류

AP.SIGNAL


[Demo video](#)

게시 전 성과 가능성 판단으로 콘텐츠 제작 단계에서의 선택과 비교 지원

국가별 기준에 따른 콘텐츠 상대 위치 제시로 글로벌 계정 운영 시 의사결정 속도 향상

실제 성과 반영 구조를 통해 변화하는 시장 환경에 지속적으로 대응 가능

단순 예측을 넘어 글로벌 콘텐츠 선택을 돕는 실무 도구로 확장 가능



남부 아프리카 중소기업 금융건강도 예측

RISKSTRAKA (이가은, 강민서, 박나림, 진규빈)

프로젝트 설명





data.org Financial Health Prediction Challenge

\$1 500 USD



Helping Eswatini, Lesotho
and 2 other countries

20 days left

Skills you will learn

Prediction

Machine Learning

1090 joined 507 active

✓ 남부 아프리카 4개국(에스와티니, 레소토, 말라위, 짐바브웨)의 중소기업의
재무적 건강 상태를 예측하기 위한 모델 구축

- 기존의 매출이나 이익 중심의 지표는 기업의 실제 재무 안정성과 회복력을 충분히 반영하지 못한다는 한계가 있음
- 이에 본 프로젝트에서는 Financial Health Index (FHI)라는 복합 지표를 활용함.

FHI는 다음 네 가지 요소를 기반으로 기업의 재무 상태를 평가함.

1. 저축 및 자산 수준 (Savings and Assets)
2. 부채 및 상환 능력 (Debt and Repayment Ability)
3. 외부 충격에 대한 회복력 (Resilience to Shocks)
4. 금융 서비스 및 신용 접근성 (Access to Credit and Financial Services)

=> 기업을 **Low, Medium, High**의 세 단계 재무 건강 수준으로 분류

프로젝트 목적

: 중소기업의 재무적 안정성과 지속가능성을 반영하는 **데이터 기반 금융 건강 예측 모델**을 구축하는 것

이를 통해...

- 금융기관이 보다 정확하게 신용 위험을 평가할 수 있도록 지원
- 정부 및 개발 기관이 재무적으로 취약한 기업을 식별하고 맞춤형 지원 정책 수립 가능
- 개발도상국 중소기업의 지속가능한 성장 촉진
- 기업의 현재 재무 상태뿐 아니라 장기적인 회복력과 성장 가능성을 반영한 새로운 평가 기준 제시

프로젝트 과정



계획 수립

1주차	데이터 전처리 및 EDA
2주차	모델링 최적화 및 성능 비교
3주차	모델 고도화 및 앙상블 적용
4주차	최종 성능 향상 및 비교
5주차	발표 자료 제작
수료식	

전처리 & EDA

<역할 분담>

이가은	기본 정보 및 사업 연령 파트	ID, country, owner_age, owner_sex, business_age_years, business_age_months, covid_essential_service, marketing_word_of_mouth, motivation_make_more_money	- ID 제거 여부 - year+month 통합 - 범주형 인코딩
진규빈	소득, 매출, 운영 상태 파트	personal_income, business_expenses, business_turnover, current_problem_cash_flow, offers_credit_to_customers, keeps_financial_records, problem_sourcing_money, future_risk_theft_stock, business_age_years, business_age_months	- 로그 변환 여부 - 극단값 처리 - 재무 파생변수
강민서	금융 접근성, 금융 도구 파트	has_mobile_money, has_cellphone, has_credit_card, has_debit_card, has_loan_account, has_internet_banking, uses_friends_family_savings, uses_informal_lender, has_insurance, medical_insurance	- 0/1 통일 - 결측치 의미 판단 - 금융 접근성 지수
박나림	태도, 인식, 보험 인식 파트	attitude_stable_business_environment, attitude_worried_shutdown, attitude_satisfied_with_achievement, attitude_more_successful_next_year, perception_insurance_doesnt_cover_losses, perception_cannot_afford_insurance, perception_insurance_companies_dont_insure_businesses_like_yours, perception_insurance_important, funeral_insurance, has_insurance	- 긍/부정 방향성 통일 - 스케일 확인 - 태도 묶음 파생변수

전처리 & EDA

이 가 은	기본 정보 및 사업 연령 파트	ID, country, owner_age, owner_sex, business_age_years, business_age_months, covid_essential_service, marketing_word_of_mouth, motivation_make_more_money	- ID 제거 여부 - year+month 통합 - 범주형 인코딩
-------------	------------------------	---	--

```
df = df.drop(columns=['motivation_make_more_money'])
```

민감한 질문 -> 결측치 너무 많고 신뢰도 낮음 ->

피쳐 제거

```
df['compliance_income_tax'] = (  
    df['compliance_income_tax']  
    .replace({'Don't know': 'Unknown', 'Refused': 'Unknown'})  
    .fillna('Unknown')  
)
```

```
df['motor_vehicle_insurance'] = (  
    df['motor_vehicle_insurance']  
    .replace({'Don't know': 'Unknown'})  
    .fillna('Unknown')  
)
```

결측치 처리

응답 거부 및 모름 결측 Unknown으로 통합해 범주 노이즈

감소

일부 범주형 결측 Missing으로 분리

```
for col in ['owner_sex', 'covid_essential_service', 'marketing_word_of_mouth']:  
    df[col] = df[col].fillna('Missing')
```

```
median_years = df['business_age_years'].median()  
df['business_age_years'] = df['business_age_years'].fillna(median_years)
```

```
median_months = df['business_age_months'].median()  
df['business_age_months'] = df['business_age_months'].fillna(median_months)
```

```
df['business_age_total_months'] = (  
    df['business_age_years'] * 12 + df['business_age_months']  
)
```

```
df = df.drop(columns=['business_age_years', 'business_age_months'])
```

**years & months 결측치 중앙값 대체 후
총 운영개월 파생변수 생성**

전처리 & EDA

진규빈	소득, 매출, 운영 상태 파트	personal_income, business_expenses, business_turnover, current_problem_cash_flow, offers_credit_to_customers, keeps_financial_records, problem_sourcing_money, future_risk_theft_stock, business_age_years, business_age_months	- 로그 변환 여부 - 극단값 처리 - 재무 파생변수
-----	------------------	---	---

```
cont_vars = ['personal_income', 'business_expenses', 'business_turnover', 'business_age_years']
```

```
cat_vars = [
    'current_problem_cash_flow',
    'offers_credit_to_customers',
    'keeps_financial_records',
    'problem_sourcing_money',
    'future_risk_theft_stock'
]
```

1) 결측치 처리 (연속형 -> median) **결측치 처리**

```
for col in cont_vars:
    df[col] = df[col].fillna(df[col].median())
```

2) 로그 변환

```
df['log_income'] = np.log1p(df['personal_income'])
df['log_expenses'] = np.log1p(df['business_expenses'])
df['log_turnover'] = np.log1p(df['business_turnover'])
```

분포 오른쪽으로 치우침

-> 로그 변환 통해 분산 완화

3) 범주형 Yes/No -> 1/0, 결측 -> 0

```
for col in cat_vars:
    df[col] = df[col].map({'Yes': 1, 'No': 0})
    df[col] = df[col].fillna(0)
```

범주형 변수 이진 변수로 변환해 수치화

4) 파생 변수 생성

총 운영 개월 수

```
df['total_business_age_months'] = (df['business_age_years'].fillna(0) * 12) + df['business_age_months'].fillna(0)
```

이익률

```
df['profit_margin'] = (df['business_turnover'] - df['business_expenses']) / (df['business_turnover'] + 1)
```

재무 취약 지수

```
df['financial_stress_score'] = df['current_problem_cash_flow'] + df['problem_sourcing_money']
```

5) 스케일링 (RobustScaler)

```
scaler = RobustScaler()
```

```
scale_cols = ['log_income', 'log_expenses', 'log_turnover', 'total_business_age_months', 'profit_margin']
```

```
df[scale_cols] = scaler.fit_transform(df[scale_cols])
```

총 운영 개월 수 파생변수 생성

생성 의도	사업 운영 기간 하나의 연속형 변수로 통합
해석	값 클수록 장기 운영 사업체 (운영 안정성 높음)

이익률 파생변수 생성

생성 의도	이익률 정의해 매출 절대값보다 수익 구조 반영
해석	값 높을수록 비용 대비 수익성 양호

재무 취약 지수 파생변수 생성

생성 의도	재무 스트레스 수준 단일 지표로 표현
해석	값 높을수록 재무 취약/스트레스 가능성 높음

전처리 & EDA

강민서	금융 접근성, 금융 도구 파트	has_mobile_money, has_cellphone, has_credit_card, has_debit_card, has_loan_account, has_internet_banking, uses_friends_family_savings, uses_informal_lender, has_insurance, medical_insurance	- 0/1 통일 - 결측치 의미 판단 - 금융 접근성 지수
-----	------------------	---	--

1. 금융 접근성 & 금융 도구 미진 변수 정리

```
binary_cols = [
    'has_mobile_money',
    'has_cellphone',
    'has_credit_card',
    'has_debit_card',
    'has_loan_account',
    'has_internet_banking',
    'uses_friends_family_savings',
    'uses_informal_lender',
    'has_insurance',
    'medical_insurance'
]
```

결측치는 0으로 처리 (보유하지 않음으로 해석) **결측치 처리**

```
for col in binary_cols:
    df[col] = df[col].fillna(0).astype(int)
```

2. 금융 접근성 지수

```
df['financial_access_index'] = df[binary_cols].sum(axis=1)
```

3. 리스크 완충 점수 (금융 접근 + 보험)

```
df['risk_buffer_score'] = (
    df['financial_access_index'] +
    df['has_insurance'] +
    df['medical_insurance']
)
```

4. 디지털 접근 점수

```
df['digital_access_score'] = (
    df['has_mobile_money'] +
    df['has_internet_banking']
)
```

5. 비공식 금융 의존 점수

```
df['informal_finance_score'] = (
    df['uses_friends_family_savings'] +
    df['uses_informal_lender']
)
```

금융 접근성 지수 파생변수 생성

생성 의도	개별 금융 도구 보유 여부보다 종합적 금융 접근 수준 측정
해석	값 높을수록 공식 금융 시스템 접근성 높음

리스크 완충 점수 파생변수 생성

생성 의도	금융 접근 + 보험 보유 결합한 위기 대응 능력 측정
해석	값 높을수록 충격 발생 시 재무적 회복 가능성 높음

디지털 접근 점수 파생변수 생성

생성 의도	디지털 금융 활용 수준 정량화
해석	디지털 금융 서비스 이용 가능성

비공식 금융 의존 점수 파생변수 생성

생성 의도	비공식 금융 의존 정도 측정
해석	값 높을수록 금융 취약 가능성 높음

전처리 & EDA

박나 림	태도, 인식, 보험 인식 파트	attitude_stable_business_environment, attitude_worried_shutdown, attitude_satisfied_with_achievement, attitude_more_successful_next_year, perception_insurance_doesnt_cover_losses, perception_cannot_afford_insurance, perception_insurance_companies_dont_insure_businesses_like_yours, perception_insurance_important, funeral_insurance, has_insurance	- 긍정/부정 방향성 통일 - 스케일 확인 - 태도 묶음 파생변수
---------	------------------------	--	--

0) 보험 장벽 인식 통합 변수

```
barrier_cols = [  
    'perception_insurance_doesnt_cover_losses',  
    'perception_cannot_afford_insurance',  
    'perception_insurance_companies_dont_insure_businesses_like_your'  
]  
barrier_cols = [c for c in barrier_cols if c in df.columns]
```

if barrier_cols:

혹시 문자열이면 숫자로 변환

```
for c in barrier_cols:  
    df[c] = pd.to_numeric(df[c], errors='coerce')
```

결측치 기준은 train에서만 계산

```
if is_train:  
    barrier_median = df[barrier_cols].stack().median()
```

```
df[barrier_cols] = df[barrier_cols].fillna(barrier_median)
```

통합 변수 생성(평균)

```
df['insurance_barrier_perception'] = df[barrier_cols].mean(axis=
```

원변수 drop 여부는 팀장 선택 (일단 유지가 안전)

```
# df = df.drop(columns=barrier_cols)
```

1) 결측치 처리 (수치형: age)

if 'age' in df.columns:

if is_train:

```
    age_median = df['age'].median()
```

```
df['age'] = df['age'].fillna(age_median)
```

2) 범주 통합 + 결측치 처리 (범주형: business_size)

```
if 'business_size' in df.columns:  
    df['business_size'] = df['business_size'].fillna('Unknown')  
    df['business_size'] = df['business_size'].replace({  
        'very_small': 'small',  
        'micro': 'small'  
    })
```

범주형 변수 세분 값 통합 및 결측 Unknown으로 처리

3) 인코딩

```
cat_cols = [c for c in ['business_size'] if c in df.columns]
```

if cat_cols:

One-Hot Encoding 적용해 범주형 변수 수치형으로

```
    if is_train:  
        encoder = OneHotEncoder(handle_unknown='ignore', sparse=False)  
        encoded = encoder.fit_transform(df[cat_cols])
```

```
    else:  
        encoded = encoder.transform(df[cat_cols])
```

```
    encoded_df = pd.DataFrame(  
        encoded,  
        columns=encoder.get_feature_names_out(cat_cols),  
        index=df.index
```

```
)  
df = pd.concat([df.drop(columns=cat_cols), encoded_df], axis=1)
```

수치형 결측치 처리

개인 모델 학습 및 최적화

1. 전처리 데이터 정리 및 수합

텍스트 정규화&결측
방어

모든 문자열 변수 정리 후 결측 Unknown으로
통일

범주형 수치화 (인코딩)

태도, 인식, 금융, 보험 변수 Yes/No 및 상태 기준으로
수치화

핵심 파생변수 생성

금융 접근성, 태도/보험 인식 지수, 사업 연령/소득 기반
지표 생성

원본 정리 & 스케일링

중복 원본 변수 제거 후 train 기준 결측 보정 및 RobustScaler
적용

최종 결과 저장

train_final & test_final 저장 후 공유

개인 모델 학습 및 최적화

2. LightGBM

타겟 분리 & 라벨 인코딩

범주형 처리 & 컬럼 정합

Train/Valid 분할

LightGBM 학습

초기 기본 학습 -> class weight 적용 후 재학습

검증 성능 평가

Test 예측 & 라벨 복원

	precision	recall	f1-score	support
0	0.34	0.59	0.43	94
1	0.87	0.83	0.85	1256
2	0.61	0.60	0.60	574
accuracy			0.75	1924
macro avg	0.61	0.67	0.63	1924
weighted avg	0.77	0.75	0.76	1924

초기 BEST f1스코어 : 0.63

개인 모델 학습 및 최적화

3. XGBoost

타겟 분리 & 라벨 인코딩

범주형 처리 & 컬럼 정합

Train/Valid 분할

XGBoost 학습

```
xgb_model = XGBClassifier(  
    n_estimators=2000,  
    learning_rate=0.05,  
    max_depth=6,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    objective='multi:softprob',  
    num_class=3,  
    eval_metric='mlogloss',  
    random_state=42,  
    early_stopping_rounds=50  
)
```

검증 성능 평가

Test 예측 & 라벨 복원

Valid Accuracy: 0.8788981288981289
Valid Macro-F1: 0.8163939170291102

초기 BEST f1스코어 : 0.81

개인 모델 학습 및 최적화

4. CatBoost

타겟 분리 & 라벨 인코딩

범주형 처리 & 컬럼 정합

Train/Valid 분할

CatBoost 학습

초기 기본 학습 -> class weight 수동 탐색 후 재학습 -> 확률 기반 threshold 튜닝 적용 후 재학습

검증 성능 평가

Test 예측 & 라벨 복원

```
Class order: ['High', 'Low', 'Medium']
Best macro F1: 0.6502654798739299 t_med: 0.39 t_high: 0.58
      precision    recall  f1-score   support

   High         0.43         0.55         0.49         94
    Low         0.88         0.80         0.84        1256
  Medium         0.59         0.67         0.62         574

 accuracy          0.75        1924
 macro avg         0.63         0.68         0.65        1924
 weighted avg         0.77         0.75         0.76        1924
```

초기 BEST f1스코어 : 0.65

개인 모델 학습 및 최적화

초기 f1 스코어 성능 비교

CatBoost 제외
XGBoost & LightGBM 두 모델
선정

개별 XGBoost & LightGBM
최적화 및 앙상블 적용

전처리 & EDA 검토 및 성능
개선

앙상블 적용 및 성능 비교

이가은	XGBoost	0.8116
	LightGBM	0.8196
	앙상블 (소프트보팅)	0.8262
	앙상블 (스택킹)	0.8229
박나림	XGBoost	0.8755
	LightGBM	0.8859
	앙상블 (소프트보팅)	0.8755

진규빈	XGBoost	0.8214
	LightGBM	0.8137
	앙상블 (소프트보팅 - OOF 기반 블렌딩)	0.8137
		0.8165
강민서	XGBoost	0.8203
	LightGBM	0.8238
	앙상블 (소프트보팅)	0.8272

프로젝트 성과



```
import numpy as np
import pandas as pd
```

```
from sklearn.model_selection import StratifiedKFold
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, LabelEncoder
from sklearn.impute import SimpleImputer
from sklearn.metrics import f1_score
```

#모델

```
from xgboost import XGBClassifier
from lightgbm import LGBMClassifier
```

```
import warnings
warnings.filterwarnings("ignore")
```

STEP 0. 데이터 불러오기

```
TRAIN_PATH = "/content/Train.csv"
```

```
TEST_PATH = "/content/Test.csv"
```

```
SAMPLE_PATH = "/content/SampleSubmission.csv"
```

```
train = pd.read_csv(TRAIN_PATH)
test = pd.read_csv(TEST_PATH)
sample = pd.read_csv(SAMPLE_PATH)
```

```
TARGET_COL = "Target"
ID_COL = sample.columns[0]
```

분류 모델 실험을 위한 기본 환경 설정 단계

- 데이터 처리, 전처리, 평가를
위한 기본 라이브러리 로드
- XGBoost, LightGBM 분류
모델 사용

#STEP 1. 학습/예측에 필요한 X, y 만들기

#Target은 y로 분류하였고, ID는 학습에 도움이 되지 않아 X에서 제거함.

```
drop_cols = [TARGET_COL]
```

```
if ID_COL in train.columns:  
    drop_cols.append(ID_COL)
```

```
X = train.drop(columns=drop_cols)
```

```
y = train[TARGET_COL]
```

```
X_test = test.drop(columns=[ID_COL], errors="ignore")
```

#STEP 2. Label Encoding (문자 라벨 -> 숫자 라벨)

#숫자 형태의 라벨이 안정적이어서 그렇게 함. (ex: Low는 0, Medium은 1, High는 2)

```
le = LabelEncoder()
```

```
y_enc = le.fit_transform(y)
```

```
n_classes = len(le.classes_)
```

모델 학습에 필요한
데이터 구조 정의

- STEP 1. 데이터 분리

- Target → y

- ID 컬럼 제거 후 X 구성

- STEP 2. 라벨 인코딩

- 문자 타겟을 숫자 라벨로 변환

#숫자형 처리 파이프라인

```
numeric_tf = Pipeline(steps=[  
    ("imputer", SimpleImputer(strategy="median")),  
])
```

#범주형 처리 파이프라인

```
categorical_tf = Pipeline(steps=[  
    ("imputer", SimpleImputer(strategy="most_frequent")),  
    #새로운 범주는 0으로 둬. (에러가 나지 않도록!!)  
    ("onehot", OneHotEncoder(handle_unknown="ignore")),  
])
```

#숫자랑 범주 컬럼을 각각 다른 전처리로 처리해주는 ColumnTransformer 사용 -

```
preprocess = ColumnTransformer(  
    transformers=[  
        ("num", numeric_tf, num_cols),  
        ("cat", categorical_tf, cat_cols),  
    ],  
    remainder="drop"  
)
```

일관된 전처리 파이프라인 구성

- STEP 3. 전처리 설계
 - 숫자형: 중앙값으로 결측치 처리
 - 범주형: 최빈값 + One-Hot Encoding
- ColumnTransformer로 전처리 통합

```
#STEP 4. Stratified K-Fold 교차검증 설정
#Stratified는 클래스 비율을 각 fold마다 비슷하게 유지하기 위해
#5-fold: 데이터 5조각을 4조각 학습, 1조각 검증으로 5번 반
skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

```
#STEP 5. xgboost 학습 + OOF 평가 + Test 예측확률 평균
```

```
#OOF (Out-Of-Fold): 각 fold에서 검증 데이터에 대한 예측을 모아서 전체 train에 대한 예측을 만들고, 검증 (val)을 계산
#Test 예측확률 평균: fold마다 학습된 모델이 test에 대해 예측 확률을 내고 그 확률을 평균냄 (안정적으로 하려고...)
```

```
#OOF 예측을 저장할 배열 (train 길이만큼)
```

```
xgb_oof = np.zeros(len(X), dtype=int)
```

```
#Test 예측확률 누적할 배열 (test_rows, 클래스 개수)
```

```
xgb_test_proba = np.zeros((len(X_test), n_classes))
```

```
for tr_idx, va_idx in skf.split(X, y_enc):
```

```
    #fold별 학습/검증 데이터 분리
```

```
    X_tr, X_va = X.iloc[tr_idx], X.iloc[va_idx]
```

```
    y_tr, y_va = y_enc[tr_idx], y_enc[va_idx]
```

```
#xgboost 모델 설정
```

```
xgb_model = XGBClassifier(
```

```
    n_estimators=2000,
```

```
    learning_rate=0.03,
```

```
    max_depth=6,
```

```
    subsample=0.8,
```

```
    colsample_bytree=0.8,
```

```
    eval_metric="mlogloss",
```

```
    random_state=42,
```

```
    n_jobs=-1,
```

```
    tree_method="hist"
```

```
)
```

교차검증과 안정적인 예측을 위한 학습 구조

● STEP 4. Stratified K-Fold 교차 검증

- Stratified 5-Fold로 클래스 비율

유지하면서 학습

● STEP 5. XGBoost 학습, OOF 평가, Test 예측

- OOF 예측으로 F1 평가
- Test 예측 확률을 fold 평균으로 산출

#전처리+모델을 하나로 묶는 pipeline

```
xgb_pipe = Pipeline([
    ("prep", preprocess),
    ("model", xgb_model),
])
```

#학습

```
xgb_pipe.fit(X_tr, y_tr)
```

#OOF 예측 저장

```
xgb_oof[va_idx] = xgb_pipe.predict(X_va)
```

#Test 예측확률 누적

```
xgb_test_proba += xgb_pipe.predict_proba(X_test) / skf.n_splits
```

#cv 성능 계산

```
xgb_cv = f1_score(y_enc, xgb_oof, average="macro")
print("XGB CV macro F1:", xgb_cv)
```

#test 확률에서 가장 큰 클래스를 최종 예측 클래스로 선택

```
xgb_pred = le.inverse_transform(xgb_test_proba.argmax(axis=1))
```

전처리와 모델을 파이프라인으로 묶어 학습,
평가, 최종 예측

- 전처리 + 모델을 pipeline을 통합
- OOF 예측으로 CV F1 성능 계산
- Test 예측 확률 기반으로 최종 파일 생성

```
lgb_model = LGBMClassifier(  
    n_estimators=3000,  
    learning_rate=0.03,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    random_state=42,  
    n_jobs=-1  
)  
  
lgb_pipe = Pipeline([  
    ("prep", preprocess),  
    ("model", lgb_model),  
)  
  
lgb_pipe.fit(X_tr, y_tr)  
  
lgb_oof[va_idx] = lgb_pipe.predict(X_va)  
lgb_test_proba += lgb_pipe.predict_proba(X_test) / skf.n_splits  
  
lgb_cv = f1_score(y_enc, lgb_oof, average="macro")  
print("LGB CV macro F1:", lgb_cv)
```

LightGBM 적용 + CV 성능 비교

- STEP 6. Lightgbm 학습 + OOF 평가 +
Test 예측 확률 평균
 - LightGBM + Stratified 5-Fold 학습
 - OOF 예측으로 CV macro F1 평가
 - Test 예측 확률을 fold 평균으로 산출

Soft Voting

- STEP 7. Ensemble (Soft Voting)
 - 두 모델의 예측 확률 평균

#STEP 7. ensemble (soft voting) - 예측 확률을 평균내서 더 안정적으로 결정

```
ens_proba = (xgb_test_proba + lgb_test_proba) / 2  
ens_pred = le.inverse_transform(ens_proba.argmax(axis=1))
```

```
sub_ens = sample.copy()  
sub_ens[TARGET_COL] = ens_pred  
sub_ens.to_csv("submission_ensemble.csv", index=False)  
print("saved: submission_ensemble.csv")
```


모델별 제출 결과 비교를 통해 성능을 검증한 최종 결과

	ID	SUBMITTED	SUBMITTER	PUBLIC SCORE	COMMENT
☐	PpMHotms	4 days ago	narim	0.878792061	나림_xgb 수정
☐	q14qP4Hm	4 days ago	narim	0.894642416	나림_lgbm 수정
☐	YUebHTgY	4 days ago	narim	0.888722609	나림_양상블 수정

- LightGBM > Ensemble > XGBoost
- 양상블은 안정적이지만 단일 최고 성능은 미달

DL 팀





딥페이크 탐지 AI 모델 개발

TRURON (안예은, 최혜윤, 장서연)

TRURON - 대회 개요

HAI! - Hecto AI Challenge 2025 하반기

1) 목표

- 생성 콘텐츠가 딥페이크(Fake)인지 진짜(Real)인지 판별하는 분류 AI 모델 개발

2) 배경

- 생성형 AI 확산으로 딥페이크가 빠르게 증가 → 금융·보안·미디어 등에서 실시간 신뢰성/안전 검증 기술 수요 증가

3) 데이터 형태

- 이미지(jpg, jpeg, png, gif) 및 영상(mp4, mov)
- 규정: 영상도 반드시 이미지 단위 입력 기반으로 판별(프레임 단위 처리)

4) 학습 데이터

- 공식 학습 데이터 미제공 → 평가용 데이터만 제공, 필요 시 외부 데이터 직접 구축

TRURON - 학습 데이터 설명


Celeb-DF: A Large-scale Challenging Dataset for DeepFake Forensics



Overview


Celeb-DF dataset includes 590 original videos collected from YouTube with subjects of different ages, ethnic groups and genders, and 5639 corresponding DeepFake videos. See [paper](#) for details (full paper will be uploaded soon).

Comparison with Other Datasets



See [paper](#) for details.

Average AUC Performance of SOTA Detection Methods on Each Dataset



TRURON - EDA

1. Test 데이터셋

1) 전체 파일 분석



- 전체 파일 수: 500
- 타입별 개수
 - video: 255 (51.0%)
 - image: 245 (49.0%)

-> 이미지/영상이 거의 1:1로 섞여 있음 → 전처리 파이프라인을 모달리티별로 분리 관리 필요

2) File size (MB)

- 파일 크기 요약 (MB)
 - mean: 3.646 / std: 7.086
 - min: 0.0118 / max: 69.831
- 분포 특성
 - 다수 파일이 0~3MB에 몰려 있고, 10MB 이상 tail이 길게 존재(최대 69.8MB)


-> 용량/압축률 차이가 큰 편이라, 모델이 '조작' 대신 '인코딩/압축 특성'으로 학습할 위험(Shortcut) 존재



TRURON - EDA

3) 전체 파일 분석

- 이미지 개수 : 245
- 해상도 요약
 - width: mean 1888, median 1280, min 213, max 8256
 - height: mean 1754.79, median 1305, min 240, max 5504
- 픽셀 수(w*h) 요약
 - mean 5.443e6, median 1.441792e6
 - min 6.2062e4, max 4.544102e7
 - (IQR) p25 7.86432e5 ~ p75 3.0e6
- Image mode
 - RGB: 224, RGBA: 21



-> 해상도 범위가 매우 넓음(최대 8256x5504) → 학습 입력은 고정 resize/center-crop 등으로 통일 필요

4) Video 해상도 (Resolution)


- 비디오 개수 : 255
- 해상도 요약
 - width: mean 1433.11, median 1920, min 284, max 1920
 - height: mean 903.96, median 1080, min 540, max 1536
- 픽셀 수(w*h) 요약
 - mean 1.388e6, median 2.0736e6
- 분포 특성
 - 1920×1080이 p50/p75 모두에서 고정적으로 나타남 (가장 지배적인 해상도)

-> 영상은 1080p(1920×1080) 중심으로 몰려 있음 → 프레임 샘플링/리사이즈 기준을 1080p 기반으로 설계하기 용이

TRURON - EDA

5) Video duration (sec)


- duration 요약 (초)
 - mean: 4.341 / std: 1.080
 - min: 2.133 / max: 8.672
- 분포 특성
 - 5초 근처에 매우 강한 피크(다수 영상이 5초 내외로 정규화된 형태)



-> 영상 길이(특히 5초 고정 패턴)는 강한 '데이터 생성/가공 흔적'일 수 있어, 모델이 길이 신호를 학습 고정해야 함

6) Video FPS

- fps 요약
 - mean: 28.155 / std: 3.073
 - min: 16, max: 32
- 분포 특성
 - 524fps와 30fps에 집중, 특히 30fps가 최빈



-> FPS 차이도 인코딩 특성(Shortcut)이 될 수 있음 → '초당 N프레임'이 아니라 '영상당 K프레임' 고정 추출이 안전

TRURON - EDA

2. Celeb-DF 데이터셋

1) 전체 영상 분석


- 전체 영상 수: 6,695
 - Fake : Celeb-synthesis(5397)
 - Real : Celeb-real(748) + YouTube-real(550)
- 프레임 수: 영상당 16프레임

-> Fake가 많음 (약 4:1), 현실 분포가 아니라 “합성 중심 분포”

2) Duration (영상 길이)

- mean : 12.55 sec
- 히스토그램 상에서 두 개의 봉우리가 보임.
 - 10~12초 / 14~16초
- Real이 평균적으로 더 김
- Fake는 생성 파이프라인 특성상 길이가 규칙적

-> 모델이 “얼굴 조작”이 아니라 영상 길이 패턴만 보고 분류할 수 있음



label	duration
Fake (0)	12.24s
Real (1)	13.79s



TRURON - EDA

3) 해상도(Resolution - Width/Height)

전체 평균

- width: 803
- height: 483
- Fake가 확실히 더 작음
- YouTube-real이 가장 큼

label	width(가로 픽셀 수)	height(세로 픽셀 수)
Fake(Celeb-synthesis)	791	481
Real(Celeb-real + Youtube-real)	854	491




TRURON - EDA

4) Brightness(밝기)

label	brightness
Fake	68.49
Real	75.03


- Real이 더 밝음
- Fake는 톤이 상대적으로 어두움



5) Contrast(대비)

label	contrast
Fake	45.96
Real	48.62


- Fake는 대비가 낮고 분산도 작음
- 전역 조명은 맞추지만 미세 대비는 손실



6) Blur (Laplacian variance)

label	blur_lapvar
Fake	50.66
Real	77.59

- 차이가 매우 큼 (약 1.5배)
- Fake 영상은 고주파(edge, texture) 정보가 사라짐
- Face blending / warping / compression 영향



TRURON - EDA

2. Celeb-DF-v2 데이터셋

1) 데이터 구성



- 전체 영상 수: 3949
 - Fake : Celeb-synthesis(3524)
 - Real : Celeb-real + Youtube-real(425)

-> Fake가 많음 (약 8:1), 극단적 합성 중심 분포

2) Duration (영상 길이)

- Fake와 Real이 유사하게 8 - 15초대에 집중 분포

-> 길이 자체는 거의 의미없는 수치



TRURON - EDA

2. Celeb-DF-v2 데이터셋



3) FPS

-> Real, Fake 둘다 유사하게 30 fps에 집중

4) 해상도

- Fake는 비표준 가로 비율 多(856x278, 852x480 등)
- Real은 좀 더 안정적인 해상도

-> Resize + Normalize 필수 / Face crop으로 차이 영향 줄일 수 있음



Top resolutions (Real)

res	count
846x476	6
850x472	5
848x472	4
834x458	4
942x500	4
844x474	4
856x478	3
850x476	3
848x466	3
812x456	3

Top resolutions (Fake):

res	count
850x472	396
848x466	345
950x500	139
852x480	126
846x476	125
846x474	123
848x472	117
944x500	105
812x456	79
834x458	71

TRURON - EDA

2. Celeb-DF-v2 데이터셋



5) Brightness

-> Fake의 분산이 Real보다 더 큼




6) RGB

- R,G,B 채널 : Fake에서 분포 범위가 매우 넓고 Real에 비해 분산이 큼

-> Fake에서 색분포가 더 불안정



RGB Channel Mean Distribution (Real vs Fake)



전체 모델링 흐름

1. 비디오에서 프레임 추출
2. 프레임 경로/라벨/그룹 ID 수집하기
3. 그룹 단위로 train/val 나누기
4. backbone(모델 종류) / face crop / augmentation 등 적용
5. 학습 / 검증
6. 제출

1) 모델 정의

- 출력 : logit 1개
- 학습 / 평가에서 sigmoid를 따로 씌워 확률로 변환

2) 얼굴 crop

- 프레임마다 얼굴 탐지
- expand=1.35 같은 값으로 박스를 넉넉히 확장해서 턱/귀/머리 경계까지 포함

3) resize

- 모델 입력 크기 통일을 위해서 얼굴 crop 결과를 224x224로 resize

4) Augmentation

- down-up 리사이즈(저해상도 시물): 40%
- JPEG 재압축(인코드→디코드): 45%
- Blur: 25%
- Noise: 25%

-> 압축 / 흔들림 / 저품질 조건 생성

5) 학습

- Loss : BCEWithLogitsLoss()
 - Optimizer : AdamW(lr, weight_decay)
1. x, y를 GPU로 올림
 2. 모델 forward → logit 출력 (B,1)
 3. BCEWithLogitsLoss(logit, y) 계산
 4. backward
 5. optimizer step (AdamW)
 6. 반복

6) 검증지표

- $p = \text{sigmoid}(\text{logits})$ 로 확률변환
- `roc_auc_score(all_y, all_p)`로 AUC 계산
 1. `val loader`로 배치 순회
 2. `logit` $\rightarrow$ `sigmoid` $\rightarrow$ `prob`
 3. 모든 `y_true` / `y_prob` 모아서 AUC 계산

7) 베스트 모델 저장

검증 AUC

-> `torch.jit.script(model)`로 스크립팅

-> `./model/model.pt` 같은 형태로 저장

1394054

submission.csv 0.5943441771

[메모 추가](#)

-

TRURON - 마무리하며

최혜윤

- GPU 문제나, 대규모 데이터셋을 다루는 데에 부족한 점이 있었던 것 같다. 하지만, 딥페이크를 감지하는 전반적인 과정과 모델링 과정에 대한 이해도가 높아진 것 같아 좋은 경험이었다.

안예은

- 학습 데이터 없이 시작하며 EDA로 해상도/길이/FPS/코덱 같은 누설(Shortcut) 위험을 먼저 점검하는 게 중요하다는 걸 체감했다. 특히 5초·30fps 중심 패턴처럼 “조작”이 아닌 “인코딩 흔적”에 모델이 끌릴 수 있어, 프레임 샘플링·입력 표준화가 핵심이라는 걸 배웠다.

장서연


- 성능을 올리기 위해 전처리(face crop, resize 등)를 열심히 시도하기보다는 모델의 성능에 의존했던 것 같아 아쉬운 점이 있었던 것 같다. 다만 cv에 있어서 eda의 중요성을 깨달았고, 전체적인 프로젝트의 흐름을 파악할 수 있어 좋았다. 또한 reference로서 여러 유사 프로젝트들을 찾아보는 등 좋은 경험을 쌓을 수 있었던 것 같다.

데이콘 SW중심대학 공동 AI 경진대회 2023

위성 이미지 건물 영역 분할 AI 개발 프로젝트

Euron 9기 Pixels팀





OVERVIEW

01

팀 소개

02

프로젝트 배경

03

EDA

04

전처리

05

모델링

06

결과 및 시각화


01

팀 소개



허정인

2242037



김서영

2329004



박예나

2491014

02 프로젝트 배경



원격탐사 기술의 비약적 발전

위성영상 및 항공사진의 해상도가 급격히 향상됨에 따라, 과거에는 식별이 어려웠던 미세한 지형과 지물까지 정밀하게 판독할 수 있는 환경이 조성되었습니다.



건물 객체 추출의 중요성 확대

국토 전역의 건물 정보를 추출하여 수치지도 갱신, 도시 계획 수립, 3D 모델링, 재난 피해 분석 등 다양한 공공 및 민간 분야 연구의 핵심 자료로 활용되고 있습니다.



기존 방식의 한계

이미지 내 건물 영역 분할 작업이 주로 사람의 수작업에 의존해왔습니다. 이는 막대한 시간과 비용이 소요되며, 작업자의 숙련도에 따라 품질 편차가 발생하는 문제점이 있습니다.



자동화 AI 모델 개발 필요

위성 이미지로부터 정밀한 건물 영역을 자동으로 분할(Segmentation)해내는 AI 기술을 통해 비용 절감, 효율성 증대, 그리고 데이터의 정확도를 동시에 확보하고자 합니다.

03 EDA

1) 데이터 무결성 및 규격 확인

Total Samples	7,140 rows	중복 및 결측치 없음
Input Size	1024 x 1024	Max RLE Index기반 추정
RLE Format	All Valid(100%)	(Start, Length) 쌍의 무결성 확인 완료

2) 마스크 통계 요약

지표	평균(Mean)	중간값(Median)	범위(Min~Max)	특이사항
면적비율(Ratio)	5.88%	4.93%	1.0%~47.5%	Class Imbalance 존재(배경 > 건물)
복잡도(Runs)	-	-	82 ~ 8,406	면적 대비 조각 수의 편차가 큼

04 전처리

1) 학습 최적화 및 증강

구분	주요 설정 및 기법	기대효과
Augmentation	RandomCrop(512), Filp(H/V)	데이터 다양성 확보 및 Overfitting 방지
DataLoader	num_workers, pin_memory, prefetch	CPU-GPU 간 데이터 전송 병목 최소화
Loss function	Soft Dice Loss(1-Dice)	클래스 불균형(건물 5%) 해소 및 직접 최적화
Metric	Dice Score(Threshold 0.5)	대회 평가 산식과 동일한 지표로 검증


2) 전처리 시 모델 구조

- 모델 아키텍처: SMP Unet(Encoder: ResNet34) 기반의 베이스라인 설정
- 최적화: AdamW 옵티마이저를 통한 안정적인 수렴 유도

Modeling Summary

Satellite Building Segmentation (Binary)

Input |



512×512

512×512 RGB
satellite tile


Output |




1-channel

Building mask
(binary, 1-channel)

Modeling Scope |



Architecture
+ Training objective (Loss)
+ Inference rule (Threshold)



✅ Model Selection: DeepLabV3+ / Mask2Former / EfficientNet 비교


🏆 Selected Fold: F5 (best validation score)

🔍 Backbone Comparison: Candidate backbone 성능 비교

→ Chosen: EfficientNet-B5 + FPN

EfficientNet-B5 backbone + FPN decoder + 1-channel segmentation head

(3) Loss Comparison Workflow



$$\mathcal{L}_{\text{BCEWithLogits}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

$$\text{Dice}_{\text{soft}} = \frac{2 \sum_{i=1}^N (p_i y_i) + \varepsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N y_i + \varepsilon}$$

$$\mathcal{L}_{\text{SoftDice}} = 1 - \text{Dice}_{\text{soft}} = 1 - \frac{2 \sum_{i=1}^N (p_i y_i) + \varepsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N y_i + \varepsilon}$$

$$\mathcal{L}_{\text{Dice+BCE}} = \mathcal{L}_{\text{BCEWithLogits}} + \mathcal{L}_{\text{SoftDice}}$$

- Controlled experiment: 모델/데이터/전처리 고정, Loss만 변경(3 runs)
 - Run#1: BCE
 - Run#2: Dice
 - Run#3: BCE + Dice
 - Why: BCE는 픽셀 단위 안정적, Dice는 클래스 불균형/영역 겹침에 강함 → BCE+Dice로 균형 기대
- Inference: logits → sigmoid → threshold(0.5) → pred mask
- Metrics: IoU / Dice(F1)
- Output: 3개 run을 한 표로 비교

결과 및 시각화

(1) Loss별 Train / Validation 지표 비교

Loss	Epoch	Train Loss	Train Dice	Val Loss	Val Dice	Val IoU
BCE	5	0.0526	0.778	0.0494	0.8034	0.6945
Dice	5	0.2654	0.7539	0.2416	0.7943	0.6822
BCE + Dice	4	0.3463	0.7716	0.3101	0.8094	0.7008


Loss 별 특징

- BCE: 픽셀 단위 최적화 우수, 과적합 최소화
- Dice: 클래스 불균형 해소 유리, 형태 보존 집중

BCE + Dice Loss가 Val IoU/Dice 등 모든 지표에서 최고점 기록 → 최종 Loss로 선정

결과 및 시각화


(1) Loss별 Train / Validation 지표 비교



BCE + Dice가 초기 epoch부터 가장 높은 Validation IoU를 유지하며 최고 성능에 도달

결과 및 시각화


(1) Loss별 Train / Validation 지표 비교



BCE + Dice가 IoU(0.701)와 Dice(0.809) 모두에서 최고 성능을 기록함

결과 및 시각화


(1) Loss별 Train / Validation 지표 비교



BCE + Dice가 시간 대비 가장 높은 Validation IoU를 달성해 성능 효율이 가장 우수함

결과 및 시각화

(2) Loss별 시각화 비교 - 세그멘테이션 오버레이 & 확률 맵



BCE Loss

- 건물 위치는 대체로 정확하나 경계가 둥글게 퍼지고 흐려지는 경향
- 경계 주변 확률이 점진적으로 감소하는 Halo 현상 발생
- 픽셀 단위 존재 여부 판단에 집중되어 형태 보존력이 낮음

Dice Loss

- 건물 내부 확신도가 높고 균일하며 경계가 상대적으로 선명
- 직선 및 모서리 형태가 잘 유지됨
- 일부 배경 영역에서 과대 예측으로 파편화된 마스크 발생

BCE + Dice Loss

- 내부는 안정적으로 채워지고 경계가 가장 깔끔하게 구분
- 정답 마스크와 시각적으로 가장 높은 일치도

결과 및 시각화

(3) Loss별 시각화 비교 - TP / FP / FN 탐색 오차 맵



BCE Loss

- 대형 건물은 잘 탐지(TP 많음)
- 인접 건물 병합으로 FP 증가
- 모서리 및 소형 건물 누락(FN) 발생

Dice Loss

- FN이 감소하여 건물 전체를 잘 탐지
- 인접 건물 분리 성능 개선
- 경계 주변 FP 일부 존재


BCE + Dice Loss

- 맞춘 영역(TP)이 가장 넓음
- FP와 FN이 동시에 줄어들음
- 밀집된 건물 지역에서도 개별 건물을 잘 구분


결과 및 시각화

(4) Loss별 시각화 비교 - FPN 다중 스케일 특징 맵


Encoder multi-scale feature 4/4 | shape=512x16x16



Encoder multi-scale feature 4/4 | shape=512x16x16



Encoder multi-scale feature 4/4 | shape=512x16x16



BCE Loss

- 배경에도 반응이 많아 노이즈가 많음
- 경계가 두껍고 흐려지는 현상 발생
- 구조적인 형태 이해 부족

Dice Loss

- 건물 내부와 경계가 비교적 균일하게 표현
- 배경 노이즈 줄어듦
- 형태는 잘 잡지만 디테일 경계 표현은 약함


BCE + Dice Loss

- 경계와 모서리가 가장 선명하게 표현
- 배경 노이즈가 잘 억제됨
- 얇고 정확한 경계 유지


결과 및 시각화

(4) Loss별 시각화 비교 - FPN 다중 스케일 특징 맵


Decoder/FPN-like feature 2/4 | p2 | shape=256x128x128



Decoder/FPN-like feature 2/4 | p2 | shape=256x128x128



Decoder/FPN-like feature 2/4 | p2 | shape=256x128x128



BCE Loss

- 특징이 흩어져서 객체 형태가 뭉치지 않음
- 인접 건물 구분이 어려움
- 전역 구조 이해가 약함

Dice Loss

- 객체 중심부 특징이 강함
- 일부 배경도 건물로 오인식
- 객체 인식은 좋아지지만 과검출 경향 존재


BCE + Dice Loss

- 건물 위치와 전체 형태가 가장 안정적으로 표현
- 객체 단위 특징이 가장 잘 모여 있음
- 인접 건물 분리도 우수

결과 및 시각화

(4) Loss별 시각화 비교 - FPN 다중 스케일 특징 맵


Decoder/FPN-like feature 3/4 | merge | shape=128x128x128



BCE Loss

→ 디테일은 많지만 노이즈와 형태 왜곡 발생


Decoder/FPN-like feature 3/4 | merge | shape=128x128x128



Dice Loss

→ 객체 형태는 잘 잡지만 경계 디테일이 부족

Decoder/FPN-like feature 3/4 | merge | shape=128x128x128




BCE + Dice Loss

→ 디테일, 형태, 안정성 모두 가장 우수

결과 및 시각화

(5) 대회 제출 결과



THANK YOU

+123-456-7890


hello@reallygreatsite.com





Moo~팀

CSIRO 캐글 대회



목차

table of contents

01

팀 소개 및
프로젝트 개요

02

데이터 탐색
및 전처리

03

모델 개발 및
학습

04

앙상블 및
성능 개선

05

과적합 해결
및 최종 결과

06

결론 및
향후 과제

팀 소개

Team introduction



팀명

Moo~




팀장 이서아

컴퓨터공학과 2466041



팀원 안지현

컴퓨터공학과 2217018



팀원 박린

컴퓨터공학과 2376096

기존 목초지 측정 방식의 문제점

1. 대규모 농장에 적용 불가
2. 시간과 비용 낭비
3. 측정 정확도가 낮고 일관성 부족

해결 방안



CSIRO - RESEARCH CODE COMPETITION - 11 DAYS AGO

Late Submission

CSIRO - Image2Biomass Prediction

Predict biomass using the provided pasture images



- 호주 전역의 다양한 계절과 지역 데이터셋 활용
- 스마트폰 이미지와 위성 NDVI 지수를 AI에 학습
- 목초의 위치와 양을 정확하게 자동 예측
- 대규모 농장에서도 효율적으로 적용 가능한 모델 개발



프로젝트 목표

위 프로젝트를 통해
우리 팀이 얻어가고자 하는 바



데이터 분석 역량 강화



이미지 분석 실전 적용

1. EDA

데이터 분석

칼럼	자료형
sample_id	object
image_path	object
Sampling_Date	object
State	object
Species	object
Pre_GSHH_NDVI	float64
Height_Ave_cm	float64
target_name	object
target	float64

범주형 칼럼

- State: NSW의 경우 타겟값과 0.4~0.6 정도의 상관 관계
- Species: 종의 종류가 너무 많고 종 간 데이터의 양이 불균등하며 상관도 낮음 → 삭제

수치형 칼럼

- Height
↔ Dry_Green: 0.65, GDM: 0.58, Dry_Total: 0.50
- NDVI
↔ Dry_Green: 0.35, GDM: 0.47, Dry_Total: 0.36

1. EDA

데이터 분석



칼럼	자료형
sample_id	object
image_path	object
Sampling_Date	object
State	object
Species	object
Pre_GSHH_NDVI	float64
Height_Ave_cm	float64
target_name	object
target	float64

Target

- Dry_Green: 클로버를 제외한 마른 녹초
 - Dry_dead: 죽은 애
 - Dry_Clover: 마른 클로버
 - GDM: 녹색 건조 물질
 - Dry_Total: total dry biomass 총 건조 바이오매스
-
- Dry_Green ↔ GDM: 0.88
 - Dry_Green ↔ Dry_Total: 0.83
 - GDM ↔ Dry_Total: 0.90

2. 데이터 전처리

Data preprocessing



데이터 전처리 전후

변경 전



1. 예측 타겟 값 5가지가 각 칼럼
2. 날짜 형식의 Sampling_Date
3. 범주형 데이터
4. 타겟과 상관도가 낮은 칼럼들



변경 후

1. Target_name 칼럼
2. 계절로 변환 ✓
3. 원핫 인코딩 수행
4. 불필요한 칼럼 삭제



1. DINO v3

Weighted R2: 0.8922

모델 구조

- DINOv3 Backbone 사용
- 사전 학습된 비전 트랜스포머
- 강력한 특징 추출 능력
- 전체 backbone freeze
& 마지막 transformer block만 unfreeze

Multi-task 회귀

- Biomass head: 5차원 회귀
- ndvi head: 1차원 회귀
- height head: 1차원 회귀
- => 3-head로 동시 예측

모델 고도화

- 데이터 증강: Mixup 기법
- 이미지 데이터 외에 수치형 데이터들은 보조 데이터로 활용
- 5-fold Cross Validation



2. SigLIP+ML Weighted R2: 0.5916

SigLIP 이미지 임베딩

- Google의 CLIP 계열 모델
- 이미지 특징을 1152차원 벡터로 변환
- 작은 데이터셋에 적합
- 효율적인 특징 추출

ML 앙상블

- HGBR, GBR, LGBM, CAT 모델 사용
- 각 모델의 강점 활용
- 4가지 모델 Lasso 스택킹

모델 고도화

- 프롬프트 최적화: Semantic Prompt 클로버 관련 프롬프트 구체화

앙상블

Model Ensemble

[SIGLIP STACKING CV RESULT]

Weighted R2: 0.5916

Dry_Green_g : 0.6291

Dry_Clover_g : 0.5602

Dry_Death_g : 0.3317

GDM_g : 0.6320

Dry_Total_g : 0.6263

[DINO CV RESULT]

Weighted R2: 0.8922

Dry_Green_g : 0.9288

Dry_Clover_g : 0.8832

Dry_Death_g : 0.7716

GDM_g : 0.9175

Dry_Total_g : 0.9006

- 타겟별 예측 성능 추출
- SigLIP+ML 모델의 경우 Dry_Death에서 낮은 성능
- => Death는 DINOv3 단독 예측, 나머지는 3:7 비율로 앙상블

[CUSTOM ENSEMBLE] SigLIP(0.3) + DINO(0.7) starting...

Target [Dry_Green_g] -> Using SigLIP(0.3) + DINO(0.7)

Target [Dry_Clover_g] -> Using SigLIP(0.3) + DINO(0.7)

Target [Dry_Death_g] -> Using 100% DINO

Target [GDM_g] -> Using SigLIP(0.3) + DINO(0.7)

Target [Dry_Total_g] -> Using SigLIP(0.3) + DINO(0.7)

결과

LB score



=====

CUSTOM ENSEMBLE CV RESULT

Weighted R2: 0.8597

=====

Dry_Green_g : 0.8863

Dry_Clover_g : 0.8434

Dry_Dead_g : 0.7716

GDM_g : 0.8859

Dry_Total_g : 0.8647

Submission and Description	Private Score ⓘ	Public Score ⓘ
 SigLIP + dinov3 6bc143 - 최종 Succeeded · letterhill · 12d ago	0.60576	0.70372
 SigLIP + dinov3 6bc143 - 앙상블 Succeeded · letterhill · 12d ago	0.61087 	0.70281




0.61277

- 최종 LB score: 0.61087
- 동메달권과 근접한 점수로 마무리

- 대용량 수치 데이터 정제·분석: NDVI, Height 등 실제 데이터 전처리 및 의미 분석 수행
- 이미지 분석 기법 적용 성공: DINOv3·SigLIP로 목초 이미지 기반 multi-task 회귀 모델 구축
- 앙상블·스태킹 성능 개선: 라쏘 스태킹과 타겟별 가중치 최적화로 CV Weighted R2 0.860, 리더보드 0.61 달성
- 과적합 관리: Sampling_Date 그룹 분리, 데이터 증강, 학습률 조정 등 기법 적용

Moo~팀

Thank you





AI 기반 뉴스 편향성 분석·요약 서비스

뉴럴타임즈 팀

팀원: 진웨이안, 김태영, 민소연, 신예나

목차

#01 프로젝트 소개

#02 데이터 수집

#03 데이터 분석

#04 주관성 분류 모델

#05 성향 분류 모델

#06 요약 모델

#07 인터페이스 구현 및 최종 데모

#08 프로젝트 성과 및 배운 점



#01 프로젝트 소개

★ AI 기반 뉴스 편향성 분석·요약 서비스 (주관성·성향·요약)

- 목적

1. AI 모델을 통해 뉴스를 (1) 주관성 탐지 (2) 진보/보수적 성향 분류 (3) 요약 텍스트 로 분석하여

사용자가 기사의 편향성을 스스로 판단할 수 있는 정량적 지표를 제시

- 2. 지능형 뉴스 큐레이션 파이프라인의 기술적 토대와 향후 확장 가능성 제시 - 프로젝트 설계

1. 뉴스 데이터 수집 (빅카인즈 / 크롤링)

2. 수집 데이터 전처리 및 분석

3. 모델링 [주관적 문장 분류 모델, 기사 본문 성향 분류 모델, 요약

모델]

4. 인터페이스 구현

#02 데이터 수집


1. 빅카인즈 ‘뉴스 검색 및 분석’서비스 이용



- 빅카인즈 (BIG KINDS): 뉴스 빅데이터 분석 서비스
- ‘뉴스 검색 및 분석’ -> 기사 데이터 수집 [861,022건]

✓ 수집 대상

- 분류: 정치/사회/경제
- 기사 발행 기간: 2020-2025 (6년)
- 언론사
 - 진보 성향 언론 : 한겨레, 경향신문
 - 보수 성향 언론 : 조선일보, 중앙일보, 동아일보



=> {‘언론사’, ‘제목’, ‘키워드’, ‘특성추출(가중치순 상위 50개)'} 칼럼 정리하여
사용

#02 데이터 수집

2. 크롤링

- 목적: 공통 사건에 대한 보수/진보 언론사별 기사의 표현 차이를 알아보기 위한 수집

✓ 수집 대상

- 대규모로 보도된 주제 **[트럼프 관세 정책 / 이태원 참사 대처 / 코로나 사태]**에 대한 뉴스

- 언론사 **한국경제, 경향신문, 조선일보, 중앙일보, 동아일보**

=> 결과

1	언론사	일자	제목	URL	label	본문
						해밀튼호텔 인근 골목에 인파 몰리며 사고 발생 병원 이송 심정지 환자 최소 21명으로 여성 다수 소방당국 대응 3단계 발령...경찰청 비상조치 발령
						'헬러원 데이'로 인파가 몰린 이태원 일대에 발생한 압사 사고로 다수의 사망자가 나왔다. 소방당국은 이번 사고로 사상자가 200명 이상 나왔다고 발표했다.
						소방당국은 30일 오전 2시40분 기준 120명이 사망하고 100명이 다쳤다고 밝혔다.
2	경향신문	20221029	이태원 '헬	https://ww	1	서울 용산구 이태원 일대에서 발생한 압사 사고로 59명이 사망하고 150명이 다쳤다고 밝혔다. 서울지하철 6호선 이태원역에서 가까운 해밀튼호텔 인근에서는 소방관과 경찰관 등이 30일 새벽까지 쓰러진 시민들을 상대로 심폐소생술(CPR)을 실시했지만 참사를 막지 못했다.
						이태원 일대에서는 헬러원 데이 기간 곳곳에서 파티가 벌어졌다. 사고는 해밀튼호텔 인

#03 데이터 분석

- 분석 대상: 빅카인즈에서 수집한 뉴스 데이터
- 목적: 빅카인즈 검색 서비스가 추출한 '키워드'의 유의미성 판단

-> 추출된 키워드 리스트를 뉴스 성향 분류 모델의 입력으로 사용해도

되는가?

- 키워드 분석: 두 진영에서 공통적으로 자주 사용하는 키워드는 불용어 처리한 뒤 분석

- 보수 언론사

- 진보 언론사



#03 데이터 분석

★ 분석 결과

1. 진영별 고빈도 키워드의 의미 차이 있음 확인 ○

- 보수 측: 경제·산업·기업, 기술·미래 산업 및 글로벌 이슈, 사건·현실 중심

키워드 ↑

- 진보 측: ... 키워드 ↑
 - 보수: ['5년', 'B씨', '각종', '감염증', '개최', '경쟁력', '공식', '공유', '그룹', '금액', '김정은', '당국', '데이터', '동시', '디지털', '마스크', '매장', '모델', '바이든', '반응', '배터리', '범행', '본인', '브랜드', '설립', '성공', '성과', '세대', '소비', '소재', '속도', '수석', '수술', '수익', '스타트업', '시험', '신종', '실적', '아들', '업계', '역대', '역량', '연속', '영국', '영업', '외국인', '우리나라', '유럽', '의대', '인근', '인수', '자녀', '조성', '주목', '주변', '지수', '진단', '채용', '출시', '판사', '페이스북', '한미', '현지', '혜택', '확진']
 - 진보: ['고발', '공약', '공천', '교육부', '구체적', '국방부', '권리', '권한', '근거', '기본', '기사', '기획', '기후', '김건희', '김씨', '노동', '노동자', '동의', '민주', '법률', '보고', '보험', '복지', '본부', '부과', '부정', '사퇴', '시간', '시점', '심사', '약속', '역사', '연대', '연장', '영장', '원칙', '의결', '의무', '의지', '이해', '인권', '임금', '작업', '장애인', '점검', '종합', '지정', '집계', '집단', '집회', '징계', '차별', '차이', '참사', '체포', '촉구', '추천', '출석', '취소', '평화', '폐지', '한반도', '행동', '행정', '현실']

2. 빅카인즈가 추출한 키워드를 기사 성향 분류 모델의 입력으로 사용하기로 함

#04 주관성 분류 모델

- 목적: 기사 본문에 포함된 문장을 주관적/객관적 문장으로 이진분류

- 데이터셋 구성

- 주관적/객관적 문장 데이터 생성 [1,600건]

1. 주관적 표현 (판단적 표현/감정적 표현) 수집

2. LLM이 생성한 주관적/객관적 문장 + 라벨링

- 사용 모델: (i) KoELECTRA, (ii) Bi-LSTM

- 데모 결과 예시

```
<class 'pandas.core.frame.DataFrame'>
Index: 1557 entries, 0 to 903
Data columns (total 2 columns):
#   Column          Non-Null Count  Dtype
---  -
0   sentences        1557 non-null   object
1   subjectivity     1557 non-null   int64
dtypes: int64(1), object(1)
memory usage: 36.5+ KB
```

	sentences	subjectivity
0	서울 아파트 거래량은 지난달 기준 3,500건을 기록하며 3개월 연속 상승세를 보였다.	0
1	이러한 구태의연한 방식으로는 미래 경쟁력을 확보하기 어렵다.	1
2	공직 사회의 무사안일주의가 국가 발전을 저해하는 암초가 되고 있다는 지적이다.	1
3	대법원은 특정 범죄 가중처벌법상 도주치상 혐의로 기소된 운전자에게 징역 1년에 집행...	0
4	중소벤처기업부는 올해 소상공인 전기요금 특별지원 사업에 총 2,500억 원의 예산을...	0

subjectivity_data.csv

(i)

```
text = "더불어민주당은 30일 국회 행정안전위 안에 구성된 안
analyze_subjectivity(text)

[{'label': 'LABEL_0', 'score': 0.9560174942016602}, {'label': 'LABEL_1', 'score': 0.04398250579833979}]

--- 분석 결과 ---
전체 문장 수: 12
주관적 문장 수: 4
최종 주관성 점수: 33.33%

33.33333333333333
```

(ii)

```
===== [종합 분석 결과] =====
● 객관적 : 30일 국토교통부·농림축산식품부 등에 따르면, 정부는 경
  ↳ 판정 근거: (DL Model: 객관적 확률 100.0%)
● 주관적 : 다만 어디로 이전할지는 입을 굳게 닫고 있다.
  ↳ 판정 근거: (DL Model: 100.0% 확신)
● 객관적 : 이전 후보지를 공개할 경우, 불필요한 혼란과 갈등이 생길
  ↳ 판정 근거: (Rule: '이유에서다'로 끝남)
● 주관적 : 정부 고위 관계자는 "특정 지역을 언급하면 토지 보상 등
  ↳ 판정 근거: (Lexicon: 단어 2개 발견, DL: 0.6%)

☑ 기사 주관성 지수: 50.0%
```

#04 주관성 분류 모델

i. KoELECTRA

- 34GB 한국어 텍스트로 학습한 트랜스포머 기반 자연어 처리 모델
- 사전 학습된 모델: Huggingface *"monologg/koelectra-small-v3-discriminator"*
- 선정 이유 (1) 자연어 분류 모델 중 성능이 좋은 모델
(2) 데이터셋 작음 -> KoELECTRA-small 선택
- 모델 입력 구조: 입력 텍스트 (한 문장) -> 이진 분류 (주관적/객관적 문장) 및 점수 계산
- 모델 학습
 - train : val : test = 8 : 1 : 1
 - 과적합 방지를 위해 모델의 일부 레이어 학습 중단

```
model = AutoModelForSequenceClassification.from_pretrained("monologg/koelectra-small-v3-discr
for name, param in model.electra.encoder.layer[:8].named_parameters(): # 일부 레이어 학습 X
    param.requires_grad = False

training_args = TrainingArguments(
    num_train_epochs=3,
    per_device_train_batch_size=16,
    learning_rate=5e-5,
    weight_decay=0.01,
    # eval_strategy="epoch",
    # save_strategy="epoch",
)
```


#04 주관성 분류 모델

ii. Bi-LSTM

- 입력 시퀀스의 양방향에서 정보를 추출하는 LSTM
- 사용 라이브러리: tensorflow
- 선정 이유: 양방향 정보 추출을 통해 문맥에서 주관성 탐지 가능한 딥러닝 모델
- 모델 입력 구조: 입력 텍스트 (한 문장) -> 이진 분류 (주관적/객관적 문장) 및 점수 계산
- 모델 학습

- train : test = 8 : 2

- 과적합 방지를 위해 드롭아웃 추가

✚ 주관성 판별 로직 추가

(1) 주관성 표현을 많이 포함하는 데이터에 직접 점수 부여

(2) 인용된 문장의 경우 분류에서 제외

(3) 간접 인용 표현이 있을 경우 객관적 문장으로 분류

모델 설계

```
model = Sequential([
    Embedding(input_dim=VOCAB_SIZE, output_dim=EMBEDDING_DIM, input_length=MAX_LEN),
    Bidirectional(LSTM(32, return_sequences=False)),
    Dropout(0.5),
    Dense(16, activation='relu'),
    Dropout(0.5),
    Dense(1, activation='sigmoid')
])
```

```
model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
```

#05 성향 분류 모델

목적

- 뉴스 기사 **제목 + 키워드**를 기반으로 **정치 성향(진보/보수)** 자동 분류
- 기사 서술 방식의 미묘한 차이를 **언어 모델이 학습하도록 설계**

학습 모델

- **KoELECTRA v3 (Base Discriminator)**
- 한국어에 특화된 ELECTRA 계열 사전학습 모델

✓ 선정 이유


- BERT 계열 대비 **학습 효율 우수**
- 한국어 정치 기사 분류에 적합

데이터셋 구성

- 데이터 출처 : 빅카인즈 (2020-2025)

성향	언론사	Label
진보	한겨레, 경향신문	0
보수	조선일보, 중앙일보, 동아일보	1

- 총 **861,044건**
- 클래스 불균형 없이 구성



#05 성향 분류 모델

모델 입력 구조

○ Sentence Pair 구조

[CLS] 제목 [SEP] 키워드 [SEP]

- **Sentence A:** 기사 제목
- **Sentence B:** 키워드(가중치 상위 50개)

✓ 제목 + 키워드를 함께 학습 → 문맥 정보 보존

모델 학습

- Train : Validation = **8 : 2**
- Epochs = **2**

Train label distribution:

label	
0	0.501458
1	0.498542

Validation label distribution:

label	
0	0.50146
1	0.49854

성능

- Validation Accuracy: **81.5%**
- 최신 기사 테스트 Accuracy: **78%**

관찰 결과

- 보수 → 진보 오분류가 더 많음
 - → **표현 중립성 차이** 가능성

Starting training...

[43054/43054 2:53:28, Epoch 2/2]

Step	Training Loss	Validation Loss	Accuracy	F1
5000	0.545682	0.568123	0.704986	0.691521
10000	0.459269	0.440345	0.787084	0.787067
15000	0.434825	0.447729	0.789564	0.788720
20000	0.423990	0.430616	0.797479	0.796962
25000	0.389520	0.419034	0.803622	0.803479
30000	0.367116	0.408694	0.810985	0.810963
35000	0.358950	0.405736	0.813192	0.812798
40000	0.360123	0.404242	0.815021	0.814760

Confusion Matrix:

[[556 82]
[198 440]]

Classification Report:

	precision	recall	f1-score	support
0	0.74	0.87	0.80	638
1	0.84	0.69	0.76	638
accuracy			0.78	1276
macro avg	0.79	0.78	0.78	1276
weighted avg	0.79	0.78	0.78	1276

#06 요약 모델

목적

- 한국어 정치 뉴스 자동 요약
- 추상 요약(abstractive summarization) 방식

학습 모델

- KoBART-base-v1

<https://huggingface.co/gogamza/kobart-base-v1>

✓ 선정 이유

- 한국어 뉴스 요약 태스크에서 가장 많이 사용되는 모델
- Encoder-Decoder 구조 → 추상 요약에 적합
- 사전학습 모델을 fine-tuning 하는 방식이 효율적

데이터셋 구성

- 데이터 출처 : AI Hub 문서요약 텍스트 데이터셋 (JSON 형태)

```
"title": "논 타작물 재배, 2월 말까지 신청하세요",  
"text": [  
  {  
    "index": 0,  
    "sentence": "ha당 조사료 400만원...작물별 차등 지원",  
    "highlight_indices": ""  
  }  
],
```

```
"abstractive": [  
  "전라남도가 쌀 과잉문제를 근본적으로 해결하기 위해 올해부터 벼를 심었던 논에 벼 대신 사료작물이  
  나 콩 등 다른 작물을 심으면 벼와의 일정 소득차를 보전해주는 '쌀 생산조정제'를 적극적으로 시행하기로 하고  
  오는 22일부터 2월 28일까지 농지 소재지 읍면동사무소에서 신청받는다 ."  
]
```

#06 요약 모델

모델 입력 구조

○ Input-Target Pair 구조

- 입력 텍스트 (Input)
 - 기사 제목 + 본문 전체
- 정답 요약 (Target)
 - abstractive[0]

모델 학습

- 지도 학습 (Supervised Fine-tuning)
- Train / Validation 분리
- Epochs = 2

모델 구조

- Encoder-Decoder
- 입력 문서를 압축 → 새로운 요약 문장 생성

성능

○ 평가 지표: ROUGE

- ROUGE-1: 단어 단위 겹침
- ROUGE-2: 2-gram 겹침
- ROUGE-L: LCS 기반 평가

✓ 요약에서 가장 표준적인 지표

Checkpoint	R-1	R-2	R-L
30498	44.8	19.2	42.0
60996	46.5	21.0	43.9

checkpoint-60996 : 최종 요약 모델로 선정

#06 요약 모델

요약 예시 (결과)

- 입력: 뉴스 기사 본문 or URL
- 출력: 핵심 사건 중심의 한 문단 요약

뉴스 URL 입력



NeuralTimes 뉴스 요약기

KoBART 기반 한국어 정치 뉴스 요약 데모

입력 방식 선택

☐ 기사 텍스트 직접 입력

☒ 기사 URL 입력

뉴스 URL 입력

요약하기

 **기사 제목**

캐나다도 영국도 중국과 관계 확대...트럼프 “위협” 경고

☒ **요약 결과**

캐나다에 이어 영국도 중국과의 관계 확대에 나서자, 도널드 트럼프 미국 대통령은 30일 프랑스 파리에서 열린 부인 멜라니아의 다큐멘터리 영화 시사회에서 영국이 중국과 사업을 하는 것은 “매우 위험하다”고 경고했다. 트럼프는 마크 카니 캐나다 총리가 최근 중국을 방문해 양국의 주요 교역품의 관세를 낮추는 무역합의를 하자, 캐나다에 고을 관 세 부과를 위협했다.

기사 본문 직접 입력



NeuralTimes 뉴스 요약기

KoBART 기반 한국어 정치 뉴스 요약 데모

입력 방식 선택

☒ 기사 텍스트 직접 입력

☐ 기사 URL 입력

기사 제목 (선택)

기사 본문

는 중국과의 관계를 맺고 있다”며 트럼프도 오는 4월에 중국을 방문할 예정임을 지적했다.

트럼프의 이런 경고에 대해 영국 총리실은 미국은 스타머 총리의 이번 중국 방문과 그 목적을 이미 알고 있다고만 지적했다.

스타머 총리는 중국 방문에 앞서 지난 27일 블룸버그 등과의 회견에서 “영국은 미국과 중국 사이에서 하나를 고르도록 강요받지 않을 것”이라고 말했다. 그는 미국과는 안보·방위·경제에서 “아주 긴밀한 관계를 유지하되”, 동시에 세계 2위 경제인 중국을 “무시하는 것은 현명하지 않다”고 강조했다. 비비시도 스타머 총리가 “나는 자주 ‘나라들 사이에서 하나를 고르라’는 요구를 받지만, 나는 그렇게 하지 않는다”고 말했다고 전했다.


트럼프가 새해 들어서 그린란드를 미국에 합병하겠다는 일방적 요구를 한 이후 미국의 동맹국들은 중국 등과 의 관계 확대를 통해 대미국 의존도를 줄이는 행보를 보이고 있다. 특히, 미국과 국경을 맞대서 형제 국가로 불리는 캐나다와 유럽에서 미국의 최고 동맹인 영국이 중국과의 관계 확대에 나서고 있다.

요약하기

☒ **요약 결과**

트럼프 대통령은 30일 프랑스 파리에서 열린 부인 멜라니아의 다큐멘터리 영화 시사회에서 영국이 중국과 사업을 하는 것은 “매우 위험하다”고 경고했으며, 마크 카니 캐나다 총리가 최근 중국을 방문해 양국의 주요 교역품의 관세를 낮추는 무역합의를 하자, 캐나다에 고을 관세 부과를 위협했다. 트럼프는 영국과 중국의 관계에 대해 더이상 언급하지는 않았으나, 곧 캐나다에 대해서 같은 경고를 재차 경고했다.

#07 Streamlit 인터페이스 최종 데모 구현



#08 프로젝트 성과 및 배운 점

프로젝트 성과

1. 주관성 분류 모델 구현 (KoELECTRA, Bi-LSTM)
2. 정치 성향 분류 모델 구현
3. 한국어 뉴스 요약 모델 구현

기대효과

- 뉴스 요약 시 불필요한 사건 제거
- 편향 분석 결과를 통해 특정 관점에 매몰되지 않는 균형 잡힌 시각을 가질 수 있도록 비판적인 뉴스 소비를 지원한다.

#08 프로젝트 성과 및 배운 점

배운 점

1. 언어 모델의 성능은 입력 구조와 전처리 설계가 핵심
 - a. 크롤링한 원시 데이터(Raw Data)에 포함된 광고 문구, 기자 메일 주소, 특수문자 등의 노이즈가 모델의 가설 검증과 성능 향상을 방해
2. 같은 뉴스 텍스트라도
 - 주관성 판별 → 분류 문제
 - 정치 성향 분석 → 문맥 기반 분류 문제
 - 요약 → 생성

태스크에 따라 모델 구조가 완전히 달라져야 함



Research 팀



Cosine 팀

TODO list를 바탕으로 이동 동선을 계획해주는 AI agent

Research 최은우 문원정 김효민

목차

1. AI agent란?
2. 프로젝트 소개 - AI-Smart-Route-Optimizer
 - 프로젝트 목표
 - 주요 기능
 - 시스템 구조
3. 결과



1. AI agent란?



AI agent

AI agent란?

- AI Agent는 단순히 질문에 답하는 AI를 넘어, 목표를 이해하고 스스로 판단·계획·행동하는 인공지능 시스템
- 주어진 목표(Goal)를 기반으로 환경을 인식(Perception)하고 필요한 행동을 계획(Planning)하며 외부 도구(API, DB, 웹 등)를 활용해 결과를 반복적으로 개선(Action & Feedback)한다.
- 도구 사용 적극적 (검색, 코드 실행, API 호출 등)
- Langgraph를 통해서 구현


2. 프로젝트 소개



AI-Smart-Route-Optimizer


프로젝트 목표 및 시스템 개요

- 사용자의 고정 일정(Fixed Events)과 할 일(To-do List)을 입력받아, 최적의 장소를 검색·선정하고 이동 효율을 고려한 최종 스케줄링 경로를 제안하는 AI 에이전트.



AI-Smart-Route-Optimizer

주요 기능



자연어 의도 분석

: "분위기 좋은 카페 가기" 같은 추상적인 할 일을 검색 가능한 키워드로 변환

실시간 장소 탐색

: 네이버 지도 크롤링(Playwright)을 통해 실제 영업 중인 최적의 장소 후보를 수집

지능형 장소 선정

: 사용자의 현재 위치와 동선을 고려하여 LLM이 최적의 장소를 최종 선택

동선 최적화

: 카카오맵 API를 활용한 거리 계산 및 논리적 추론을 통해 이동 거리를 최소화하는 스케줄을 확정

AI-Smart-Route-Optimizer

시스템 구조

- LangGraph를 사용하여 상태 기반(Stateful) 워크플로우로 동작
 - Ingest Node: 사용자 입력 데이터 전처리 및 좌표 변환
 - Candidate Node: 할 일(Todo) 분석 및 네이버 지도 크롤링
 - Selection Node: 후보지 중 최적의 장소 확정 (LLM)
 - Distance Node: 모든 지점 간 거리 행렬(Distance Matrix) 계산
 - Optimization Node: 전체 동선 효율성 분석 및 최종 스케줄 생성



AI-Smart-Route-Optimizer

시스템 구조

▼ Meta
> Target Date 2026-01-01
> User House Address 서울시 용산구 독서당로 111
> User Id user_123
> User Workplace Address 서울시 서대문구 이화여대길 52
▼ End Point
> Address 서울시 용산구 독서당로 111
> Name 집
▼ Coordinates
> X 127.007307641122
> Y 37.5361228594578
▼ Start Point
> Address 서울시 용산구 독서당로 111
> Name 집
▼ Coordinates
> X 127.007307641122
> Y 37.5361228594578

AI-Smart-Route-Optimizer

시스템 구조

```

  Fixed Events
  0
    Category lecture
    End Time 15:00
    Id fixed_1
    Location 서울시 서대문구 이화여대길 52
    Start Time 13:00
    Title 컴퓨터구조 강의
    Type fixed
    Coordinates
      X 126.950288837762
      Y 37.5644645178259
  1
    Category workout
    End Time 20:00
    Id fixed_2
    Location 서울시 서대문구 이화여대길 59
    Start Time 19:00
    Title PT
    Type fixed
    Coordinates
      X 126.945159029873
      Y 37.5589881516307

```

↗ Polly

AI-Smart-Route-Optimizer

시스템 구조

```

  ▾ Todo Items
    ▾ 0
      > Center Place 학교 근처
      > Id todo_1
      > Status need_recommendation
      > Title 서점 가서 책 사기
      > Type todo
      > Candidates []
      > Duration 60
      > Final Choice null
    ▾ Search Words
      > 0 대형 서점
      > 1 전공 서적

```

AI-Smart-Route-Optimizer

시스템 구조

- LangGraph를 사용하여 상태 기반(Stateful) 워크플로우로 동작
 - Ingest Node: 사용자 입력 데이터 전처리 및 좌표 변환
 - Candidate Node: 할 일(Todo) 분석 및 네이버 지도 크롤링
 - Selection Node: 후보지 중 최적의 장소 확정 (LLM)
 - Distance Node: 모든 지점 간 거리 행렬(Distance Matrix) 계산
 - Optimization Node: 전체 동선 효율성 분석 및 최종 스케줄 생성



3. 결과



AI-Smart-Route-Optimizer

배포

- LangGraph로 구축한 상태 기반(Stateful) 에이전트 로직을 FastAPI 기반의 서버에 통합
- LangServe의 add_routes 기능을 활용해 복잡한 구현 없이 RESTful API를 자동 생성
- Uvicorn을 사용하여 비동기 웹 서버를 실행하고, 실시간 요청 처리가 가능하도록 배포

AI-Smart-Route-Optimizer

LangServe Playground (Input)

LangServe Playground

Try it

Inputs

USER ID*

user_123

TARGET DATE*

2026-01-01

USER HOUSE ADDRESS*

서울시 용산구 독서당로 111

USER WORKPLACE ADDRESS*

서울시 서대문구 이화여대길 52

START POINT*

{ "name": "집", "address": "서울시 용산구 독서당로 111" }

END POINT*

{ "name": "집", "address": "서울시 용산구 독서당로 111" }

FIXED EVENTS

[{"title": "컴퓨터구조 강의", "location": "서울시 서대문구 이화여대길 52", "start_time": "13:00", "end_time": "15:00", "category": "lecture"}, {"title": "PT", "location": "서울시 서대문구 이화여대길 59", "start_time": "19:00", "end_time": "20:00", "category": "workout"}]

TODO LIST RAW

[{"task": "서점 가서 책 사기", "user_duration": 60, "center_place": "학교 근처", "search_words": ["대형 서점", "전공 서적"]}, {"task": "조별 과제 회의 준비", "user_duration": 90, "center_place": "학교 근처", "search_words": ["스터디룸", "회의실"]}, {"task": "분위기가 좋은 카페가서 커피 마시기", "user_duration": 60, "center_place": "집 근처", "search_words": []}]]

EMHA
Euron

AI-Smart-Route-Optimizer

LangServe Playground (처리과정)

```
DEBUG [Ingest]: 원본 할일 리스트(처리후) = 3개 발견  
--- [NODE 1] 완료: Meta, Fixed(2), Todo(3) 생성됨 ---
```

```
--- [NODE 2] 후보지 탐색 및 크롤링 프로세스 시작 ---  
> 3개의 할 일에 대한 검색어 생성 중...
```

```
Generating search words: 100% | 3/3 [00:01<00:00, 1.82it/s]
```

```
> 네이버 지도 크롤링 및 장소 후보 수집 시작...
```

```
Crawling: 서대문구 서점...
```

```
서대문구 서점 데이터 수집 완료!
```

```
브라우저 리소스를 해제합니다
```

```
좌표 재시도 (유어마인드) -> 최종 검색어: '유어마인드'
```

```
좌표 재시도 (알라딘 중고 신촌점) -> 최종 검색어: '알라딘'
```

```
좌표 재시도 (홍익문고) -> 최종 검색어: '홍익문고'
```

```
Crawling: 서대문구 스타디움...
```

```
서대문구 스타디움 데이터 수집 완료!
```

```
브라우저 리소스를 해제합니다
```

```
좌표 재시도 (윙스터디 신촌스타디움) -> 최종 검색어: '윙스터디'
```

```
좌표 재시도 (어스스타디카페 신촌1호점강조대여) -> 최종 검색어: '어스스타디카페'
```

```
좌표 재시도 (르하임스타디카페 연희점) -> 최종 검색어: '르하임스타디카페'
```

```
Crawling: 용산구 카페...
```

```
용산구 카페 데이터 수집 완료!
```

```
브라우저 리소스를 해제합니다
```

```
좌표 재시도 (카페멜랑) -> 최종 검색어: '카페멜랑'
```

```
좌표 재시도 (르몽생미셀 르 카페) -> 최종 검색어: '르몽생미셀'
```

```
좌표 재시도 (헬로 시드니 베이커리) -> 최종 검색어: '헬로'
```

```
--- [NODE 2] 후보지 탐색 완료 ---
```

```
--- [NODE 3] 장소 최종 선택 및 좌표 확정 시작 ---
```

```
✓ 확정: 홍익문고 (좌표: 126.937030051858, 37.5557973589999)
```

```
✓ 확정: 윙스터디 신촌스타디움 (좌표: 126.9347703988, 37.5566034259156)
```

```
✓ 확정: 카페멜랑 (좌표: 126.927203755899, 37.5551898432728)
```

```
--- [NODE 4] 거리 행렬(Distance Matrix) 생성 시작 ---
```

```
> 총 7개 지점 간 거리 계산 중...
```

```
--- [NODE 4] 완료: 거리 행렬 생성 완료 ---
```

```
DEBUG [Optimize]: 전달받은 고정 일정 개수 = 2
```

```
로그: 결과가 output/result_20260203_163054.json에 저장되었습니다.
```

AI-Smart-Route-Optimizer

LangServe Playground (Output)

```
{
  "total_distance": 24475,
  "schedule": [
    "0. 집 - 출발 [00:00]",
    "1. fixed_1 (컴퓨터구조 강의) - 강의 [13:00~15:00]",
    "2. todo_3_candidates_1 (카페멜랑) - 커피 마시기 [15:00~16:00]",
    "3. todo_1_candidates_3 (홍익문고) - 책 사기 [16:00~17:00]",
    "4. todo_2_candidates_1 (윙스터디 신촌스터디룸) - 과제 회의 준비 [17:00~18:30]",
    "5. fixed_2 (PT) - 운동 [19:00~20:00]",
    "6. 집 - 도착"
  ],
  "reasoning": [
    "[Step 1. 고정 일정 확인] - 다음 고정 일정을 타임라인 뼈대로 설정: 1) 컴퓨터구조 강의(13:00~15:00, 이화여대길 5)",
    "[Step 2. 지역 군집화] - 거리 행렬에서 10m 이하 그룹 분석: 1) fixed_1과 fixed_2 사이 거리 758m, 2) todo_1과 todo_2 사이 거리 7374m",
    "[Step 3. 대안 비교 및 틈새 삽입] - 최적화 결정 과정: 1) todo_3(집 근처 카페)는 귀가 직전 배치 시 거리 7374m 발",
    "[Step 4. 수치 검증] - 최종 거리 합산: 1) 집->fixed_1: 5933m, 2) fixed_1->todo_3: 2281m, 3) todo_3->todo_1: 869m",
    "[Step 4. 수치 검증 (재계산)] - 실제 적용된 거리: 1) 집->fixed_1: 5933m, 2) fixed_1->todo_3: 2281m, 3) todo_3->fixed_2: 7374m"
  ]
}
```

Thank You



AI_TOP100

주최 kakao!impact Brian Impact 후원 과학기술정보통신부 kakao

다양한 AI 도구 이해 및 활용 능력

방대한 양의 자료 속
필요한 정보만 쏙쏙 집어내거나
뛰어난 코딩 실력 없이도
간단한 앱을 개발하는 등
업무와 일상 속 복잡한 문제들을
AI와 함께 해결할 수 있나요?

AI 사용 제한
없음!



- 주요 속성:
 - id: 전투 고유 ID
 - blue, red: 팀별 유닛 정보 배열
 - unit_id: 유닛 고유 ID
 - type: 유닛 종류 (aleo, bras, cbene, dgreg, eyanoo)
 - at: 유닛의 2차원 좌표(x, y) (예: "9,0")
 - winner: 해당 전투의 승리팀 ("blue" 또는 "red")

- 데이터 변환 → to csv : ChatGPT, 코딩

	id	blue_type_1	blue_pos_1	red_type_1	red_pos_1	blue_type_2	blue_pos_2	red_
0	battle_00001	cbene	4,16	bras	16,12	N/A	N/A	
1	battle_00002	dgreg	4,15	bras	18,10	N/A	N/A	

- 1vs1 전투 → count : ChatGPT, 코딩

	Total Games	Total Wins	Win Rate (%)
dgreg	107	81	75.70
cbene	87	52	59.77
aleo	109	57	52.29

- 유닛별 상성 계산? -> 1vs1 전투 결과 활용
 - 카운트 결과 -> gemini, 최종 정리

```
def get_matchup_result(row):
    if row['winner'] == 'blue':
        return pd.Series([row['blue_type_1'], row['red_type_1']], index=['Winner_Unit', 'Loser_Unit'])
    else:
        return pd.Series([row['red_type_1'], row['blue_type_1']], index=['Winner_Unit', 'Loser_Unit'])

matchups = one.apply(get_matchup_result, axis=1)
advantage_counts = matchups.groupby(['Winner_Unit', 'Loser_Unit']).size().reset_index(name='Count')

# 보기 좋게 정렬 (A > B 형태)
advantage_counts['Matchup'] = advantage_counts['Winner_Unit'] + ' > ' + advantage_counts['Loser_Unit']
final_result = advantage_counts[['Matchup', 'Count']].sort_values(by='Count', ascending=False)
|
print(final_result)
```

	Matchup	Count
8	dgreg > aleo	30
10	dgreg > eyanoo	29
0	aleo > bras	29
3	bras > dgreg	26
6	cbene > bras	26
4	bras > eyanoo	24
2	aleo > eyanoo	22
9	dgreg > cbene	22
5	cbene > aleo	22
12	eyanoo > cbene	7
1	aleo > cbene	6
7	cbene > eyanoo	4
11	eyanoo > bras	3

인수인계



인수인계 자료 작성

업무 기록을 참고하여 인수인계 문서를 작성하는 문제

문서요약

멀티모달

챌린지 시작 →

문제 개요 및 접근 전략

상황 설정

- 전임자 김하늘 이 인수인계 없이 사라짐
- 후임자 홍지은 이 2025.07.21 시점에서 워크스페이스 데이터만으로 업무 파악

제공 데이터 (5가지 유형)

이메일 195개 → 캘린더 26개 → 메모 31개 → 이미지 4개 → 통화 7개

풀이 전략

1단계: Python으로 텍스트 데이터 자동 수집 (메일/캘린더/메모)

2단계: 멀티모달 데이터 변환 (이미지/음성 → 텍스트)

3단계: 정보 추출 및 교차 검증으로 객관식 문제 해결

4단계: Template.md 형식에 맞춰 최종 문서 작성

문제 1~3: 객관식 문제 풀이 (각 15점)

문제 1: AutoFlow 교육 장소는? (15점)

정답: 3층 대회의실

- 📞 통화 파일 2025_07_18.m4a 분석
- ✉️ 이메일 교차 검증
- ✅ "2025년 7월 25일(금) 오후 2시, 3층 대회의실"

문제 2: 리크루팅 컨택 완료 대학 수는? (15점)

정답: 4개

- 📝 메모 202507_대학리스트_편최종.docx (2025.07.19 작성) 확인
- ✅ 일산대, 꽃동네대학교, 부산대, 청주대
- ⚠️ 버전 관리 주의: 최종본 vs 최최종 vs 편최종

문제 3: 8월 1일이 아닌 시작일 찾기 (15점, 복수선택)

정답: OmegaERP 도입 (9/1), 하계 인턴십 (8/5)

- ❌ 출장 숙박비: 실제 18만원 (문제는 15만원)
- ✅ 출장 식비: 8/1 시작 맞춤
- ❌ OmegaERP: 9/1 오픈 (8/1 아님)
- ✅ 법인카드: 8/1 시작 맞춤 (500→800만원)
- ❌ 하계 인턴십: 8/5 시작 (8/1 아님)

문제 4: 인수인계 문서 작성 (30점)

평가 기준 (AI 자동 채점)

- 1. 거짓/불필요 정보 제거: 근거 없는 추측 배제
- 2. 사실 정보 완전성: 7개 섹션 모두 채우기
- 3. 템플릿 형식 준수: 테이블 컬럼명, 구조 일치

핵심 작성 원칙

- ✓ 2025.07.21 시점 기준: 지난 일정(7/21 이전) 제외
- ✓ 최신 정보 우선: 같은 내용의 여러 버전 중 최신 채택
- ✓ 교차 검증: 메일↔통화↔메모 정보 일치 여부 확인
- ✓ 구체성: "IT팀 김태현 과장", "내선 1234" 등 상세 기재

인수인계 문서

- 전임자: 김하늘
- 작성일: 2025.07.21
- 후임자: 홍지은

1. 업무 개요

현재 인사팀 내에서 인사 기획 및 운영 전반을 담당하고 있으며, 주요 업무는 '정기 인사 운영', '채용 절차 관리', '사내 교육 프로그램 기획 및 진행'입니다.

2. 정기업무

2.1 인사 운영 업무

업무명	주기	내용	마감일/주의사항
월말 정산	매월 말	입/퇴사자 전산 접근 권한, 장비 반납 리스트 체크	매월 마지막 금요일
급여 처리	매월	급여 데이터 검토 및 처리, 4대 보험 처리, 원천세 신고	매월 20일 마감, 25일까지 처리
구내식당 식역 미팅	매월	식당 메뉴 품질 점검 및 개선사항 논의	매월 마지막 금요일
주간 근태 현황 확인 및 보고	매주 월요일	사내 시스템 데이터 기반 주간 근태 보고	매주 월요일 09:30

2.2 교육 관련 업무

3. 진행 중인 프로젝트

3.1 시스템 전환 및 도입

프로젝트명	현황	다음 단계	마감일
OmegaERP 도입	75% 완료 (데이터 이전 완료, 정합성 검증 진행 중)	IT팀(김태현 과장)과 데이터 정합성 최종 확인, 8월 말 전 직원 교육 실시	2025.09.01 오픈
모바일 오피스 도입	ExampleWork 앱 출시 준비 완료	전사 도입 공지 및 사용법 교육 안내	2025.08.01

3.2 채용 및 인재 개발

프로젝트명	현황	다음 단계	마감일
대학 리크루팅	4개 대학 컨택 완료 (일산대, 꽃동네대, 부산대, 청주대)	7월 말 이후 추가 대학 컨택, 10개 대학 목표	2025.09.30
하반기 채용 계획	부서별 요청 취합 중	7/28 최종 인원 및 일정 확정 회의	2025.07.28
하계 인턴십	계획 수립 완료 (8/5~8/30, 4주, 10명 모집)	채용 공고 게시 및 면접 일정 조율, 프로그램 운영	2025.08.05 시작

3.3 직원 복지

프로젝트명	현황	다음 단계	마감일
하반기 동호회 운영	현재 8개 동호회 80명 운영	요가/사진여행/캠핑 시그 등 신규 취미가 지	7/27 오리엔테이션

PDF 속 스텔스 텍스트 추적기

Task – AI 보안, 프롬프트 인젝션

- 문서 속에 의도적으로 숨겨진 텍스트 찾아내기
- 디지털 낙서 또는 AI 평가 과정에 부적절하게 개입하려는 의도를 가진 텍스트 검출하기
- 5문제 (객관식 4문제, 주관식 1문제) - 총점: 90점 (10점, 15점, 15점, 10점, 40점)

* 문제 접근 전략

1. PyMuPDF 라이브러리 사용해 PDF 내 특정 조건의 텍스트 필터링 (코드 풀이)
2. ChatGPT, Gemini, Claude 사용해 프롬프트로 텍스트 검출
+ 원본 PDF 파일 확인을 통해 직접 정답 검증




1. 문제 요약

PDF 문서에 의도적으로 숨긴 텍스트를 검출하고, 검출된 영역의 텍스트를 추출하세요.

숨겨진 텍스트는 문서 맥락과 무관하거나, AI 기반 자동 평가 시스템을 오도해 긍정적 결과를 유도하도록 조작하는 목적을 갖고 있으며, 숨겨진 텍스트의 일반적인 형태는 다음과 같습니다.

- 보이는 내용 아래에 있는 보이지 않게 숨겨진 텍스트
- 백색 텍스트 혹은 극소 폰트 크기의 텍스트
- 배경색과 유사한 색상의 텍스트가 포함된 이미지

- 1 pdf_1.pdf (Advanced AI System Technical Specifications)에는 '이미지 기반 pdf에 배경과 비슷한 색상으로 숨겨진 텍스트'가 있습니다 (총 14단어로 이루어진 한 문장). 이 텍스트를 찾아 답변란에 입력해 주세요.
- 2 pdf_2.pdf (Simple, Spatial, Survey Method (S3M II) SUDAN)에는 '흰색의 작은 텍스트'가 있습니다 (총 11단어로 이루어진 한 문장). 이 텍스트를 찾아 답변란에 입력해 주세요.
- 3 pdf_3.pdf (EcAMSat – NASA's first 6U Biological Spacecraft)에는 '눈에 보이는 레이어 아래에 보이지 않는 텍스트'가 있습니다 (총 5단어로 이루어진 한 문장). 이 텍스트를 찾아 답변란에 입력해 주세요.
- 4 pdf_4.pdf (The Inheritors)에는 총 5개의 문장이 '다양한 방식'으로 숨겨져 있습니다. 각 문장은 유명한 영어 노래 가사 중 일부입니다. 숨겨진 텍스트를 찾아 페이지 순서대로 제출해주세요.



2. 문제 풀이 및 후기

접근 전략

① PDF 구조 분석

- PyMuPDF / pdfplumber로 텍스트 레이어(span 단위) 추출
- 폰트 크기, 색상, 투명도, 위치 분석
- 극소 폰트 / 흰색 텍스트 / 여백 텍스트 필터링

② 시각적 변환 실험

- 모든 텍스트를 파란색으로 재삽입
- 원본과 비교하여 숨겨진 텍스트 확인

③ LLM 활용

- 문제 설명을 그대로 프롬프트로 입력
- 숨겨진 문장 추론
- "디지털 낙서 / 프롬프트 인젝션 여부" 관점에서 분석

풀이 결과

코드+LLM로 도출한 답 중 PDF에서 직접 검증된 것만 정답이었던 것으로 예상되며(70점 중 30점), 나머지는 LLM hallucination으로 추정된다.

풀이 후기

- 모델이 보이는 것 뿐 아니라 파일 특성을 분석 가능
 - 흰색/극소/레이어 아래 텍스트도 LLM은 인식함
 - LLM은 힌트 기반 추론에 쉽게 유도됨
 - 그럴듯한 오답(hallucination) 발생
 - 코드는 구조적 숨김에, LLM은 맥락적 추론에 강함 단일 방식은 위험
 - 코드 + LLM 교차 검증이 최적 전략일 것
- ➡ AI는 파일 구조와 의도를 완전히 구분하지 못하고 그럴듯한 답을 만들어내는 한계가 있으며, 인간의 검증과 비판적 개입이 반드시 필요하다.
-