

ROGII 지질 시추 데이터로 TVT 예측하기

ROGII Wellbore Geology Prediction

6주간의 ML 프로젝트 회고

수직 구간
(제공 데이터)

PS

수평 구간 (예측 대상)

오늘 이야기할 순서

1

이 대회는 무엇을 맞히는 문제인가

문제 정의와 데이터 구조 소개

2

데이터가 알려준 함정 두 가지

6주 내내 부딪힌 근본 원인

3

6주 동안의 시행착오

10가지 시도와 하나의 성공

4

최종 1등 모델 분석

같은 재료, 다른 결과

5

이 프로젝트에서 배운 것

ML 이론 교훈 5가지

이 대회는 무엇을 맞히는 문제인가

수평 시추정(horizontal well)이 지나가는 길의
수직 깊이(TVT)를 예측하는 문제입니다.

6,125

참가팀 수

5.639 ft

1등 RMSE

11.427 ft

최종 RMSE

수직 구간
(제공 데이터)

PS

수평 구간 (예측 대상)

Typewell
(참고 지도)

데이터 생김새 & 채점 방식



수평정 데이터

위치(X,Y,Z), 감마선(GR), 그리고
정답인 TVT — 1피트 간격으로 기록



Typewell 데이터

같은 지역을 수직으로 뚫었을 때의
GR-깊이 기준표 (참고 지도)

한눈에 보는 규모

773개

학습용 웰

약 200개

테스트용 웰

73%

예측 대상 구간 비율

RMSE란?

예측한 깊이와 실제 깊이가 평균적으로 몇 피트 차이 나는지를 나타내는 오차값.
값이 작을수록 정확하게 맞힌 것입니다.


함정 ① 수평 구간에선 거의 안 움직인다

수직 구간에서는 깊이가 빠르게 증가하지만,
수평으로 꺾이는 순간 깊이 변화가 거의 멈춥니다.

그래서 방향을 꺾기 직전 마지막 값을 그대로 복사해 쓰는
가장 단순한 방법(Constant Baseline)이 오히려 매우 강력했습니다.

프로젝트 Constant 기준선

15.883 ft



함정 ② 믿었던 피처가 정반대로 배신한다

학습 데이터에는 지금 위치에서 지층 경계까지의 거리를 알려주는 피처가 6개 있었습니다.
이 피처와 정답의 상관관계를 구간별로 확인해보면 아래와 같은 결과가 나옵니다.

예측 전 구간 (PS 이전)

+0.72



예측 구간 (PS 이후)

-0.91

결정적으로, 이 6개 컬럼은 실제 테스트 데이터에는 아예 존재하지 않습니다.

가설 세우고, 실험하고, 원인 분석하고

이 사이클을 6주 내내 반복했습니다. 시도한 방법 10가지 중 성공은 단 1개였습니다.



방법	결과	RMSE
Constant Baseline	기준선	15.9 ft
패턴 매칭류 (DTW · Beam Search · NCC)	실패	24~262 ft
추세 외삽류 (선형 · Z좌표 · EGF회귀 · EGFDL)	실패	23~34 ft
CrossWell XGBoost (다른 웰 활용)	실패	16.7 ft
Particle Filter	성공	11.4 ft

① 과거 추세를 미래로 끌고 가려던 시도들

X	선형 외삽 PS 직전 200개 행의 기울기를 그대로 연장	33.78 ft
X	Z좌표 비율 적용 수평 이동 거리(Z)와 깊이의 비율을 이후 구간에 적용	23.85 ft
X	지층거리 피쳐 회귀 (EGF) 6개 피쳐로 회귀 모델 학습	25.92 ft
X	지층 추적 (EGFDL Tracking) 드릴이 지층과 일정 거리를 유지한다고 가정	27.12 ft

공통 원인 : 수직 구간의 추세는 방향이 바뀌는 순간 수평 구간에 전혀 적용되지 않습니다.

② 패턴을 억지로 맞추거나, 남의 웰을 끌어온 시도들

X

DTW / Beam Search / NCC

감마선 패턴을 정밀하게 매칭하려던 시도

24 - 262 ft

X

CrossWell XGBoost

다른 웰 데이터를 모아 함께 학습

16.74 ft

왜 패턴 매칭이 실패했나

수평 구간 감마선 값이 ± 10 정도로 거의 평탄해서,
매칭할 정보량 자체가 부족했습니다.


왜 다른 웰 데이터가 실패했나

지역이 다르면 지층 패턴 자체가 다릅니다.
신호는 그 웰 안에서만 찾아야 한다는 확신을 얻었습니다.

파티클 필터란?

정답 위치를 모를 때, 여러 **후보 위치**를 흩뿌려 놓고

새로운 정보가 들어올 때마다 후보들의 신뢰도를 조정해가며 정답에 수렴시키는 방법입니다.



새 관측값마다
가중치 업데이트



정답에 수렴

핵심 수정

감마선으로 시작 위치를 추측하지 않고,
PS 시점에 이미 아는 값을 그대로 시작
점(앵커)으로 사용 → 편향 제거


파티클 필터 개선 & 프로젝트 최종 성적

시작점 고정 외에도, 월별로 신뢰도를 다르게 주고
128개 시드를 반복 실행해 평균을 내는 방식으로 안정성을 높였습니다.

외부 코드 없이 순수하게 직접 구현해서 낸 최고 기록입니다.

28% 개선

RMSE 비교



최종 1위 유저의 문제 정의 방식

프로젝트 방식 — 숫자 하나 맞추기

지금 깊이가 몇 피트인지 하나의 숫자를 맞추는 회귀 문제




1위 방식 — 확률 지도 그리기

감마선 패턴이 기준 지도의 어느 위치와 가장 잘 들어맞는지, 모든 후보의 확률을 계산



확률 지도 생성에 딥러닝 이용



U-Net 구조 (개념도) — 압축했다가 다시 복원하며 위치 정보를 그려냄

사진에서 물체 위치를 찾을 때 쓰는 구조(U-Net + ConvNeXt)를 그대로 가져와서, 감마선 패턴을 이미지처럼 취급해 학습시켰습니다.

773개 웰이라는 적은 데이터에도, 이미 대량의 이미지로 미리 학습된 모델을 재사용(전이학습)해서 안정적으로 학습할 수 있었습니다.

지도를 그리는 방식

숫자 대신 기준 지도(타입웰)의 400개 후보 위치 전체에 "여기일 확률이 몇 %"를 색칠하는 히트맵을 통째로 그리게 했습니다. 정답을 하나로 우기지 않고 가능성을 넓게 열어둔 덕분에, 큰 실수를 대폭 줄일 수 있었습니다.

1위 모델 구조를 분석하며
어떤 식으로 ML과 DL이 협력하는지
알게 되었습니다.

기타 최종 1위의 모델 분석

1	데이터 보정	타입웰과 실측 감마선의 눈금 차이를 미리 보정	35%↓
2	데이터 증강	“깊이+수평거리는 항상 일정” 물리 법칙으로 데이터를 무한 생성	무한 생성
3	양방향 추적	전체를 다 본 뒤 미래 정보로 과거 추정을 재보정	양방향
4	공간 정보 활용	가까운 이웃 웰의 지층 경사를 가중치 반영해 보정	+공간정보
5	앙상블	성격이 다른 6개 모델의 예측을 섞어 오차를 상쇄	5.639 ft

프로젝트 vs 1위, 한눈에 비교

	프로젝트	1위
문제 정의	숫자 하나 맞추기 (회귀)	확률 지도 그리기 (정렬)
모델	파티클 필터만	딥러닝 + 파티클 필터 + 공간정보 앙상블
데이터 보정	원본 그대로 사용	눈금 보정 적용
데이터 증강	없음	물리 법칙 기반 증강
최종 성적	11.427 ft	5.639 ft

올바른 접근 방향

웰 단위 독립 접근 · 파티클 필터라는 방향 · 감마선 + 타입웰 매칭 패러다임

이 프로젝트에서 배운 ML 교훈 5가지

1

문제 정의가 알고리즘보다 중요할 수 있다

“숫자 맞추기”를 “정렬하기”로 문제 정의 수정

2

전처리 하나가 모델 복잡도보다 클 수 있다

감마선 눈금 보정 하나로 35% 개선

3

물리 법칙은 최강의 데이터 증강이다

“TVT+Z 불변” 법칙으로 무한한 학습 데이터 생성

4

불확실하면 끝까지 확률로 들고 가라

숫자 하나로 일찍 단정 짓지 않기

5

표본이 큰 지표를 믿어라

작은 Public LB보다 전체 교차검증(CV)

이 프로젝트에서 얻은 것

수많은 피쳐들을 어떤 방식으로 엮을 것인지, 어떤 가중치를 부여할 것인지, 그리고 실제 도메인 지식을 공부해서 2차 검증 방식으로 어떻게 녹여낼 것인지, 피쳐와의 상관관계를 면밀하게 연구하는 게 훨씬 중요하다는 것을 새삼 깨달았습니다.

왜 안 되는지 분석한 뒤 다음 방법을 시도하며
각 ML 이론들이 실전에서 어떤 장단점을 가지는지 직접 경험한 6주였습니다.

정답 없는 문제를 스스로 정의하고 검증한 경험 자체가
가장 값진 결과라고 생각합니다.

감사합니다.

Constant Baseline

15.883 ft



프로젝트 최종 성적

11.427 ft

28% 개선, 순수 자체 구현

1등 (Private LB) : 5.639 ft