



당뇨병 위험군 예측 및 자가진단 웹서비스 개발

Euron ML 1팀 김세연, 박채윤, 안서영

목차

#01 프로젝트 소개 및 진행 과정

#02 데이터 소개

#03 전처리

#04 EDA

#05 머신러닝 모델 학습

#06 모델 성능 비교 및 최종 모델 선정

#07 하이퍼파라미터 튜닝

#08 웹서비스 소개

#09 웹서비스 시연

#10 기대 효과

#11 한계점 및 향후 개선 방향




#01 프로젝트 소개 및 진행 과정



#01 프로젝트 배경

Prevalence of Diabetes and Prediabetes in Korean Adults



Data from the Korea National Health and Nutrition Examination Survey (2019–2022) were analyzed.

출처 : 대한당뇨병학회 Fact Sheet 2024

1. 당뇨병 관리의 중요성

30세 이상 성인 **7명 중 1명**은 당뇨병
10명 중 4명은 당뇨병 전단계

2. 문제점

높은 당뇨병 & 전단계 유병률
→ 개별 건강검진 수치만으로 위험도를
직관적으로 파악하기 어려움

3. 프로젝트 필요성

건강검진 데이터를 활용한
당뇨병 자가진단 서비스 필요

#01 프로젝트 목표

01 데이터 분석

건강검진 데이터를 분석하여 **당뇨병 위험군의 주요 특성 탐색**

02 위험군 예측 모델 개발

여러 머신러닝 모델을 비교하고 **최종 모델을 선정**하여 당뇨병 위험군 예측


03 자가진단 웹서비스 구현

Streamlit을 활용해 건강검진 정보를 입력하면 예측 결과의 **위험도를 확인**할 수 있는 서비스 구현

* 이 프로젝트에서 ‘**자가진단**’은 질병에 대한 의료적 진단을 의미하기보다, 사용자가 건강검진 정보를 입력해 자신의 당뇨병 위험군 여부와 예측 위험도를 스스로 확인하는 것을 의미함

#01 프로젝트 진행 과정

진행 과정



#02 데이터 소개



#02 데이터 소개

데이터셋 소개

데이터 출처

- 국민건강보험공단 건강검진정보 데이터
- 공공데이터포털 제공



데이터 특징

- 건강검진 수검자의 신체계측, 혈액검사, 생활습관정보 포함
- 당뇨병 위험군 예측을 위한 건강검진 데이터 활용

데이터 규모

- 원본 데이터 : 약 100만 건
- 전처리 후 : 330, 775건

#02 데이터 소개

입력 변수 (X) - 총 20개



신체계측

- 키, 체중, 허리둘레



혈압

- 수축기, 이완기 혈압



혈액 검사

- 콜레스테롤, 중성지방, AST, ALT, 감마지티피 등



생활습관

- 흡연 여부, 음주 여부

예측 변수 (y)


공복 혈당을 기준으로 생성한 **당뇨병 위험군 여부** - 'Target' 변수 (0 / 1)

#03 데이터 전처리



#03 데이터 전처리

전체 전처리 흐름



#03 데이터 전처리

핵심 전처리 내용

01 Target 생성

- **당뇨병 위험도**인 Target 변수 생성
- 공복혈당 < 100mg/dL → 정상군(0)
- 공복혈당 ≥ 100mg/dL → 위험군(1)

* 공복혈당 100~125mg/dL은 공복혈당장애(당뇨병 전단계)
범위에 해당 - 출처 : 질병관리청

02 불필요 변수 제거

- Target 생성에 사용한 공복혈당 제거
- 시력, 청력 제거

03 결측치 처리

- 결측 행 제거

04 이상치 처리

- 건강검진 데이터 특성상 제거하지 않고 유지

05 파생변수 생성

- 키와 체중으로 **BMI** 생성
- **BMI** : 대표적인 비만 지표


#04 EDA



#04 EDA - 위험군 분포


01 정상군 & 위험군 분포

- 정상군 약 57.4%, 위험군 약 42.6%
- 정상군과 위험군이 비교적 **균형 있게 분포**하여, 심각한 클래스 불균형이 나타나지 않음



02 연령대별 위험군 비율


- **연령대가 높아질수록** 위험군 비율이 **증가**
- 낮은 연령대 16% -> 높은 연령대 50% 증가



#04 EDA - 생활습관 특성에 따른 분포


01 흡연 상태별 위험군 비율

- 비흡연 : 39.6%
- 과거 흡연 : 49.6%
- 현재 흡연 : 46.0%
- **흡연 경험이 있는 집단에서 비흡연 집단보다 당뇨병 위험군 비율이 높음**



02 음주 여부에 따른 위험군 비율

- 뚜렷한 패턴이 나타나지 않음



#04 EDA

건강지표 비교 및 주요 변수

지표	정상군 평균	위험군 평균
BMI	23.71	25.04
수축기혈압	122.19	127.41
이완기혈압	74.84	77.37

- 위험군은 정상군보다 BMI와 수축기 & 이완기혈압이 전반적으로 높게 나타남



#04 EDA

Target과의 상관관계

상관관계가 높게 나타난 주요 변수

- 허리둘레 : 0.210
- 연령대 : 0.205
- 수축기혈압 : 0.176
- BMI : 0.173
- 트리글리세라이드 : 0.171



* 허리둘레와 연령대가 Target과 상대적으로 높은 양의 상관관계를 보임

* 수축기혈압, BMI, 트리글리세라이드도 위험군과 관련된 주요 변수로 확인됨

#05 머신러닝 모델 구축



#05 머신러닝 모델 구축

#1 데이터 준비

#2 머신러닝 모델 구축

#3 성능 평가 지표

#05 머신러닝 모델 구축

1. 데이터 준비

- **데이터셋:**
diabetes_preprocessed.csv 사용
- **Target 변수 설정:** 당뇨병 위험군 여부
- **결측치 처리:** 결측치 행 제거
- **데이터 분할:** Train / Test 데이터 8 : 2 비율 분할

2. 머신러닝 모델 구축

- **Logistic Regression:** 선형 분류
베이스라인
- **Decision Tree:** 트리 구조 기반의
직관적 모델
- **Random Forest:** 앙상블 기법으로
오버피팅 완화
- **XGBoost:** 그래디언트 부스팅
기법으로 고성능 도출

3. 성능 평가 지표

- **Accuracy:** 전체 예측 중 정답 비율
- **Precision:** 위험군 예측 중 실제
위험군 비율
- **Recall:** 실제 위험군 중 모델이 맞춘 비율
- **F1-score:** Precision과 Recall의
조화평균

#06 모델 성능 비교 및 선정



#06 모델 성능 비교 및 선정

#1 모델 성능 비교

#2 최종 모델 선정

#06 모델 성능 비교 및 선정

모델 성능 비교

- **평가 대상:** Logistic Regression, Decision Tree, Random Forest, XGBoost (총 4개)
- **평가 방식:** 동일한 Test Dataset에 대해 Accuracy, Precision, Recall, F1-score 측정
- **비교 결과:**

전반적인 예측 정확도 및 균형 지표에서 XGBoost 알고리즘이 가장 우수한 성능을 기록함.

#06 모델 성능 비교 및 선정

모델 성능 비교

첫 번째 데이터 예측확률
[0.7408693 0.25913072]

=====

모델 성능 비교

	Model	Accuracy	Precision	Recall	F1-score
3	XGBoost	0.667518	0.663944	0.667518	0.663826
2	Random Forest	0.661426	0.657157	0.661426	0.655587
0	Logistic Regression	0.651434	0.646557	0.651434	0.644533
1	Decision Tree	0.644420	0.639324	0.644420	0.638237

#06 모델 성능 비교 및 선정

최종 모델 선정

최종 선정 모델: XGBoost

선정 이유:

Accuracy, Precision, Recall, F1-score 전 영역에서 최고

점수 달성

당뇨병 위험군 분류 모델로서 종합적인 예측 정확도 및

안정성이 가장 높음

웹기반 자가진단 서비스를 위한 최종 예측 엔진으로 최종

확정

#07 하이퍼파라미터 튜닝



#07 하이퍼 파라미터 튜닝

#1 튜닝 기법 및 평가 방법

#2 하이퍼 파라미터

#3 모델 최종 성능

#07 하이퍼 파라미터 튜닝

튜닝 기법 및 평가 방법

- **탐색 기법:** GridSearchCV (격자 탐색) 적용
- **검증 기법:** 5-Fold Cross Validation 적용으로 일반화 성능 확보
- **최적화 최우선 기준:** F1-score (Weighted)
- 데이터 불균형 및 오분류 리스크 최소화를 위한 다각적 검토 진행

튜닝 대상 주요 파라미터

- **n_estimators:** 생성할 부스팅 트리 개수 탐색
- **max_depth:** 개별 트리의 최대 깊이 제어 (오버피팅 방지)
- **learning_rate:** 각 트리의 기여도를 조절하는 학습률
- **subsample:** 트리를 훈련할 샘플링 비율
- **colsample_bytree:** 트리 생성 시 특성 샘플링 비율

#07 하이퍼 파라미터 튜닝

✓ 최적 하이퍼파라미터 조합:

`n_estimators = 200 | max_depth = 5 | learning_rate = 0.1 | subsample = 1.0 | colsample_bytree = 0.8`

66.90%

Accuracy

66.56%

Precision

66.90%

Recall

66.55%

F1-score

✓ 최종 파이프라인 연동: XGBoost 최종 모델 확정 완료 → model.pkl 포맷으로 저장 완료 → Streamlit 웹 서비스 연동

#08 Streamlit 웹서비스



서비스 구성 및 설계

- 가독성을 위해 두 페이지로 분리
- 사용자가 데이터와 모델을 충분히 이해한 후 예측 서비스를 이용할 수 있도록 설계



프로젝트 개요

프로젝트 안내 ➡ EDA 핵심 시각화 리포트
➡ 모델 성능 비교 및 XGBoost 선정 근거
제시



당뇨병 위험도 예측

건강검진 정보 입력 ➡ XGBoost 기반
당뇨병 위험도 계산 ➡ SHAP 기반 Top3
영향 요인 & 맞춤형 생활 습관 제시

당뇨병 위험도 예측 - 입력창

- 각 변수에 맞는 위젯 사용
- 입력 범위를 제한하여 잘못된 입력으로 인한 모델 에러 방지

당뇨병 위험군 예측 및 자가진단

건강검진 정보를 입력해주세요

기본 정보	혈압	신장 기능
성별 남자	수축기 혈압 (mmHg) 120	요단백
연령대 20~24세	이완기 혈압 (mmHg) 80	혈청 크레아티닌 (mg/dL) 1.00
신장 (cm) 165.00	혈액 검사 총 콜레스테롤 (mg/dL) 180	간 기능 혈청 자오티(AST) (IU/L) 20
체중 (kg) 65.00	트리글리세라이드 (mg/dL) 150	혈청 자피티(ALT) (IU/L) 20
하리둘레 (cm) 80	HDL 콜레스테롤 (mg/dL) 50	감마지피티 (IU/L) 20
생활 습관 흡연 상태 비흡연	LDL 콜레스테롤 (mg/dL) 100	
음주 여부 마시지 않음	혈색소 (g/dL) 15.00	

당뇨병 위험도 예측하기

연령대

50~54세

20~24세

25~29세

30~34세

35~39세

40~44세

45~49세

50~54세

55~59세

170.00


Error: Number is outside the allowed range. Please enter a value between 40 and 700. (L)

체중 (kg)

1500

당뇨병 위험도 예측 - 결과창(저위험군)

당뇨병 저위험군(Low Risk Group)



현재 입력된 건강검진 정보를 바탕으로 당뇨병 저위험군으로 예측되었습니다.

건강한 생활습관을 유지하시고, 정기적인 건강검진을 권장합니다.

※ 본 결과는 머신러닝 모델의 예측 결과이며 의학적 진단을 대체하지 않습니다.

예측에 가장 큰 영향을 준 건강 요인 (SHAP)

저위험군 예측에 가장 크게 기여한 요인

1. 연령대
2. 감마지티피
3. 수축기혈압

생활습관 개선 권장사항


건강한 생활습관 유지하기

- 절주 및 금주 실천
- 저염식 실천
- 규칙적인 유산소 운동
- 당분이 많은 음식 섭취 줄이기
- 정기적인 건강검진 받기

현재 좋은 예측 결과에 기여한 건강 요인을 유지하는 것을 권장합니다.

당뇨병 위험도 예측 - 결과창(고위험군)

당뇨병 고위험군(High Risk Group)



현재 입력된 건강검진 정보를 바탕으로 **당뇨병 위험군**으로 예측되었습니다.

생활습관 관리와 정기적인 건강검진, 필요 시 전문의 상담을 권장합니다.

※ 본 결과는 머신러닝 모델의 예측 결과이며 의학적 진단을 대체하지 않습니다.

예측에 가장 큰 영향을 준 건강 요인 (SHAP)

고위험군 예측에 가장 크게 기여한 요인

1. 트리글리세라이드
2. 허리둘레
3. 혈청크레아티닌

생활습관 개선 권장사항

생활습관 개선 권장사항

- 당류 및 음주 줄이기
- 규칙적인 유산소 운동
- 복부 지방 감소를 위한 유산소 운동
- 정제 탄수화물 섭취 줄이기
- 당분이 많은 음식 섭취 줄이기
- 정기적인 건강검진 받기

위 권장사항은 이번 예측에 영향을 준 건강 요인을 바탕으로 생성되었습니다.

당뇨병 위험도 예측 - 결과창

부호(Sign) 기반 SHAP 분기 로직

- **양수(+) SHAP (고위험군)**
: 당뇨 위험도를 **상승시킨** 주원인 Top3 추출
- **음수(-) SHAP (저위험군)**
: 당뇨병 위험도를 **낮춰준** 건강 유지 요인 Top3 추출

SHAP 분석으로 도출된 핵심 요인과 자동 매핑

➔ 맞춤형 권장 사항과 공통 권장 사항 제안

* 직접 개선이 어려운 요인에 대해서는 매핑 X

ex) 트리글리세이드 ➔ 당류 및 음주 줄이기 & 규칙적인 유산소 운동
연령대 ➔ X

▼ 예측에 가장 큰 영향을 준 건강 요인 (SHAP)

🔍 고위험군 예측에 가장 크게 기여한 요인

1. 감마지티피 (SHAP = 0.353)
2. 트리글리세라이드 (SHAP = 0.191)
3. 수축기혈압 (SHAP = 0.129)

▼ 생활습관 개선 권장사항

📋 생활습관 개선 권장사항

- 절주 및 금주 실천
- 당류 및 음주 줄이기
- 규칙적인 유산소 운동
- 저염식 실천

맞춤형 권장사항

- 당분이 많은 음식 섭취 줄이기
- 정기적인 건강검진 받기

공통 권장사항

위 권장사항은 이번 예측에 영향을 준 건강 요인을 바탕으로 생성되었습니다.

#09 서비스 시연



#서비스 시연

 당뇨병 위험군 예측 및 자가진단 프로젝트

#10 기대 효과



#10 기대효과



위험군 조기 인지

- 건강검진 정보를 바탕으로 **당뇨병 위험도를 직관적으로 확인**
- 사용자가 자신의 **건강 상태에 관심**을 갖는 계기 제공



건강관리 행동 유도

- **예측 결과와 주요 영향 요인**을 함께 제시
- 생활습관 개선 및 정기적인 **건강검진의 필요성** 인식



데이터 기반 자가진단 서비스

- 머신러닝 모델을 실제 웹서비스로 구현
- 누구나 쉽게 이용할 수 있는 **건강관리 참고 도구** 제공

#11 한계점 및 향후 개선 방향



#11 한계점

01 제한된 변수

- 건강검진 데이터 중심으로 가족력, 식습관, 운동량 등 주요 위험요인 미반영

02 모델 성능의 한계

- 최종 정확도 약 66.9%
- 실제 의료적 진단을 대체하기 어려움

03 모델 일반화의 한계

- 단일 건강검진 데이터셋을 기반으로 모델 학습
- 다양한 집단 및 실제 환경에서의 추가 검증 필요

#11 향후 개선 방향

01 데이터 확장

- 가족력, 식습관, 운동량 등 **다양한 위험요인** 추가

02 모델 고도화

- 다양한 모델과 튜닝 방법 비교
- 불균형 처리 및 임계값 조정 검토

03 서비스 기능 개선

- 사용자 **맞춤형 건강관리** 정보 제공
- 모바일 UI 및 입력 편의성 개선
- 다양한 사용자 대상 서비스 검증

THANK YOU

