


EURON 프로젝트

RESEARCH SEOMEET

MULTIMODAL HUMAN ACTION QA

EURON 10th RESEARCH 장서연, 이서아, 고은서



CUHK-X COMPETITION LARGE MODEL TRACK

 GVINE15 · COMMUNITY PREDICTION COMPETITION · A MONTH TO GO

[Submit Prediction](#) ...

CUHK-X Competition Large Model Track

Using Powerful Model to answer questions

[Overview](#) [Data](#) [Code](#) [Models](#) [Discussion](#) [Leaderboard](#) [Rules](#) [Team](#) [Submissions](#)

Overview

Watch short privacy-preserving videos of people performing everyday home activities and answer questions about them — recognizing what action is performed, understanding how it unfolds, and reasoning about the objects involved. This is the **Large Model Track**: there is no model-size limit, and large vision-language models and APIs are welcome.

Goal: Predict the answer to every question in the test set. The test set is made of **held-out subjects** never seen in training (cross-subject), so your model must generalize to new people. Standings are decided by the **private** leaderboard (the public leaderboard is for reference only).


- For more information, please visit our official website: <https://openaiotlab.github.io/CUHK-X-Challenge/>
- Please register on our official website before participating, and ensure your Kaggle team name matches the team name registered on the official website. This is required so that our team can send you award certificates and shortlist notifications.

Competition Host
Gvine15 

Prizes & Awards
\$10,000
Does not award Points or Medals

Participation
351 Entrants
132 Participants
119 Teams
962 Submissions


Tags
[Custom Metric](#)



주제 설명

- 캐글 대회 링크: <https://www.kaggle.com/competitions/cuhk-x-competition-large-model-track/overview>
- 영상 및 센서 기반 인간 행동 데이터를 활용하여 질문에 대한 정답을 예측하는 멀티모달 QA(Question Answering) 모델을 개발하는 프로젝트
- Large Vision-Language Model(LVLM)을 활용하여 사람의 행동, 객체 사용, 상황 흐름 등을 이해하고 추론하는 능력을 학습, 새로운 사람 데이터에도 일반화 가능한 모델 구현
- 평가: 전체 정확도 (682 테스트 문항, 부분점수 없음)

- **training_qa.csv** — the training set
- **test_qa.csv** — the test set
- **sample_submission.csv** — a sample submission in the correct format (qa_id,answer).
- **HAU.zip, HARn.zip** — the training media: the video clips referenced by the path column.
- **large_model_track_test.zip** — the test media: the clips for the test questions.



Task: Multimodal Video Question Answering

모델은 무엇을 예측하는가?

Multimodal Video + Question + Answer Choices(A/B/C/D) → VLM Model → Answer(A/B/C/D)

- Training = 3,912 clips / 4,087 questions
- Testing = 208 clips / 682 questions

```

├── Training/
│   ├── training_qa.csv  # qa_id, question, A/B/C/D, answer
│   ├── modality_list.csv # which modalities each clip has
│   └── data/
│       ├── HARn.zip → HARn/<action>/<user>/<trial>/<modality>/<modality>.mp4
│       └── HAU.zip  → HAU/<user>/<trial>/<modality>/<modality>.mp4
└── Testing/
    ├── test_qa.csv  # questions only
    └── data/
        └── large_model_track_test.zip
  
```



Q. Which action is performed in this video?

- A. Jumping jacks
- B. Checking the time
- C. Stir drinks**
- D. Brushing teeth



HAU- 행동 인식 (사람의 행동을 이해하고 추론)

- single — 어떤 행동인가? → Watching TV
- multi — 어떤 동작들이 등장하는가?
- combination — 어떤 행동의 조합인가?
- sequence — 동작의 시간 순서는?
- emotion — "What emotion does the person express?" → Urgently, Anxiously

HARn - 행동 추론 (사람의 행동과 물체의 상호작용)

- single — 사람이 무엇을 하는가? → eating
- object_interaction — 어떤 사물과? → newspaper

 Dataset Overview - Multimodal Human Activity Data


Visual sensors (.mp4)

- **IR:** 적외선 실루엣 영상
- **Depth_Color:** 거리를 색으로 표현
- **Depth:** 거리 흑백 맵
- **Thermal:** 열화상 (온도) - 사람의 열 분포와 움직임

No RGB → Privacy-preserving

Non-Visual sensors


- **IMU:** 웨어러블 5개(가슴, 양팔, 양다리) 움직임 시계열
- **Radar:** mmWave point cloud, 위치, 속도 포착
- **Skeleton:** 관절 좌표 스틱 피규어, 애매한 동작 보완




(338, 9)


	timestamp	frame	DetObj#	x	y	z	v	snr	noise
0	2025-06-01 14:22:07.417	274	0	-0.002068	0.053618	0.038711	0.0	167	557
1	2025-06-01 14:22:07.417	274	1	0.009304	0.289744	-0.067907	0.0	122	482
2	2025-06-01 14:22:07.417	274	2	-0.051691	0.754246	0.335359	0.0	162	482
3	2025-06-01 14:22:07.417	274	3	-1.569341	0.251663	1.497066	0.0	130	642
4	2025-06-01 14:22:07.417	274	4	-0.409393	2.085955	-0.498561	0.0	130	642

Index(['timestamp', 'frame', 'DetObj#', 'x', 'y', 'z', 'v', 'snr', 'noise'], dtype='object')





EDA - Visual sensors (.mp4)




Source	QA 수	센서(모달리티)	난이도 특징
HARn (보조)	562	Depth, Depth_Color, IR	행동 인식 위주, 쉬운 문제
HAU (주력)	3,525	Depth, Depth_Color, IR, Thermal	다양한 reasoning 문제, 어려움


```
train[train["path"] == "HAU/user2/4-1-1"]
```

	qa_id	category	question	A	B	C	D	answer
50	training_0051	single	Which action is performed in this video?	Pouring	Wiping hands	Using a phone	Combing hair	C
859	training_0862	multi	Which of the following actions appear in this ...	Using a phone	Mopping	Undressing	Taking a selfie	A
1665	training_1670	combination	Which combination of actions is performed in t...	Walking, Calling	Sweeping, Wiping hands	Walking, Sweeping	Wiping hands, Calling	A
2429	training_2436	sequence	What is the correct temporal order of the foll...	Using a phone	Walking	Calling	Writing	ACDB
2766	training_2774	emotion	What emotion does the person in the video expr...	Leisurely	Impatiently	Evenly	Calmly	A




source	num_questions	count
HARn	1	486
	2	38
HAU	3	19
	4	482
	5	308



- 카테고리 별 채점 기준
 - single, combination, emotion, object_interaction → 정확히 한 글자 (exact match)
 - multi → 여러 글자, 순서 무관 (set 비교, 부분점수 없음)
 - sequence → 여러 글자, 순서까지 정확히 일치해야 함
- 주요 특성
 - 같은 영상(path)에 여러 질문이 달려 있는 경우가 많음 (최대 5개 질문/영상)
 - 학습 데이터의 약 1.2%는 Depth_Color 모달리티 자체가 없는 결측 샘플 존재 (Depth, IR만 있음)
 - **HARn**: 보통 single, object 둘 중 하나의 질문만
 - **HAU**: Train과 Test 모두 보통 하나의 영상에 대해 여러가지 질문이 달려오는 경우가 많음



EDA - Visual sensors (.mp4)




Duration 분포

: FPS는 거의 일정하여, 영상 길이를 기준으로 frame 수를 조절하는 방향.

- train: 대체로 5~25초, 일부 40~70초대 존재
- test: 대체로 5~20초, 일부 30~40초대 존재

짧은 영상은 중복 정보가 많고 긴 영상은 행동 변화·순서 정보를 놓칠 수 있다는 문제가 있어 category 별 대신 길이 기반으로 frame 수 조절




Sampling 방식 3종

- **Adaptive uniform sampling**: 전체에서 균등 추출 → [single](#), [emotion](#), [sequence](#)
- **Motion-based sampling**: grayscale 변환 후 프레임 간 pixel 차이가 큰 구간 우선 선택
 - → 행동 변화 포착에는 유리하나 [순서 정보가 사라져 단독 사용은 부적합](#), [보조용으로만 사용](#)
- **Hybrid sampling (uniform + motion)**: 시작/중간/끝 프레임은 반드시 포함, 나머지는 motion score가 큰 구간에서 선택 → [multi](#), [combination](#)

Motion summary feature

Feature	의미
motion_mean	영상 전반의 평균 움직임 크기
motion_std	움직임 변화량의 변동성
motion_max	가장 큰 움직임 변화량
motion_sum	영상 전체 움직임 변화량의 총합
motion_peak_pos	가장 큰 움직임이 발생한 상대적 위치
motion_active_ratio	평균보다 큰 움직임이 발생한 구간의 비율

전처리 전략: 제한된 Visual Information 보완



- IR 영상: RGB 대비 제한 적인 시각 정보
- Sample frame을 추출하여 모델링 → 시간적 변화를 일부 손실하게 됨
- Nonvisual sensor로 영상이 놓치는 움직임 정보 보완

→ IR 영상의 밝기를 개선하고, IMU, Radar, Skeleton에서 움직임 정보를 추출해 보완

IR 영상의 불균일한 밝기 문제



Dark

→ 인물과 배경 형태 파악이 어려움



Overexposed

→ 흰 옷 등 밝은 영역이 과노출됨



Mixed

→ 밝은 부분과 어두운 배경이 동시에 존재함

=> 모든 영상에 동일한 밝기 보정을 적용하기 어렵다고 판단

영상 밝기 분석

영상마다 여러 프레임을 균등하게 추출한 뒤 밝기 통계 계산

- p2: 하위 2% 밝기
- p5: 하위 5% 밝기
- p50: 중앙값 밝기
- p95: 상위 5% 밝기
- p98: 상위 2% 밝기
- dark_ratio: 픽셀값 25 이하 비율
- bright_ratio: 픽셀값 245 이상 비율
- contrast: p95 - p5

통계값	의미
p50	영상 전체가 대체로 얼마나 밝은가
dark_ratio	화면에서 거의 검은 부분이 얼마나 많은가
bright_ratio	화면에서 거의 흰 부분이 얼마나 많은가
contrast	사람과 배경의 밝기 차이가 충분한가
p2 , p5	어두운 부분이 얼마나 심하게 어두운가
p95 , p98	밝은 부분이 얼마나 심하게 밝은가

💡 평균 밝기 사용하지 않은 이유

- 밝은 부분+어두운 부분이 섞여 있는 경우
- 일부 하얀색 색상의 가구만 과노출되는 경우

→ 이런 케이스에서는 평균 밝기로 판단하기 어려움

영상 밝기 분석

원본
overexposed



원본
dark



condition	의미	사용한 기준
dark	영상 전체가 전반적으로 어두움	영상 가운데 밝기인 p50 이 낮거나, 검은 부분인 dark_ratio 가 많음
mixed	어두운 영역과 밝은 영역이 함께 존재	검은 부분도 많고, 거의 흰 부분도 함께 존재함
overexposed	밝은 픽셀이 많이 포화됨	거의 흰 픽셀인 bright_ratio 가 많거나 p95 가 255에 가까움
low_contrast	명암 차이가 작아 윤곽이 흐림	p95 - p5 가 작아서 영상 전체가 비슷한 회색임
normal	별도 밝기 보정이 크게 필요하지 않음	위 조건에 해당하지 않음

Selective Gamma Correction

시도한 방법들과 문제점

Percentile 스트레칭: 영상이 뿌옇짐 → 제외

CLAHE: 구역별 명암 대비 → 노이즈 강조 → 제외

전체 프레임 단일 감마: 밝은 영역 과노출

최종 방식: 어두운 영역만 선별적으로 감마 보정

- 어두운 픽셀 → 감마 보정 강하게
- 중간 밝기 → 보정 강도 점점 감소
- 밝은 영역 → 원본 그대로 유지
- 감마 마스크 경계에만 약한 블러 적용

실제 보정 결과



과노출은 원본을 유지하고, 어두운 영역만 선택적으로 보정함

Nonvisual 센서 분석

IMU

- 원본 데이터: 가속도+각속도
- 추출 정보: 움직임 강도 / 상·하체 중심 / 급격함 / 시점

Radar

- 원본 데이터: 3D Point Cloud
- 추출 정보: 공간 이동 / 속도 / 반사점 변화

Skeleton



- 원본 데이터: 3D keypoints
- 추출 정보: 자세 변화 / 높이 / 중심 이동 / temporal motion

Activity Level

Body Focus


Peak Timing

Motion Style



초기 fusion 방식


Sensor-to-Text Fusion



[SKELETON CUE]

- Reliability: good.
- Articulated body movement is high.
- The strongest pose change occurs in the middle part.

1차 결과



→ 모든 센서를 결합했을 때 오히려 성능 하락

Category별 성능

[combination]

Visual + Skeleton → +0.011

[multi]

Visual + Skeleton → +0.030

→ 모든 문제에 동일한 방식으로 prompt 정보를 추가한 것이 문제!

개선된 fusion 방식

Skeleton 센서를 이용한 Sampling 방식

BEFORE



AFTER




Visual 정보와 중복 · temporal detail 압축 · noise 증가

Sensor를 prompt에 추가하는 정보로 제공하는 대신에, 모델이 어디를 볼지 결정하는 데 사용


개선된 fusion 방식

Skeleton 센서를 이용한 Sampling 방식



- Skeleton motion timeline 계산
- 움직임 peak detection
- peak 주변 IR frame 선택
- 시작/중간/끝 temporal anchor 유지
- quality가 낮으면 uniform sampling fallback
- IR 밝기 보정은 동일하게 유지

개선 결과



22.22% → 26.26%

+4.04% / +4 문제 정답

Insight

1. Selection 효과

Uniform 8f 22 / 99

Skeleton-guided 25 / 99

→ +3 questions

2. More frames ≠ Better

Guided 8f 25/99

Guided 12f 23/99

3. Selective cue

Guided 8f + quality-filtered Skeleton cue

→ 26 / 99

Key Finding


더 많은 정보 → 더 나은 정보

단순 Fusion

IR + IMU + Radar + Skeleton



Performance ↓



선별적 Fusion

Skeleton → 중요 시점 선택



Enhanced IR + minimal cue



Performance ↑

모델링 접근 전략

입력 최적화

어떤 센서 영상을 쓸지,
프레임을 몇 장 어떻게 뽑을지,
프롬프트를 어떻게 쓸지

추론 구조 개선

같은 모델이 같은 입력을 보더라도,
답을 뽑아내는 절차를 바꾸기

모델 자체 교체

더 복잡한 모델로 교체

입력 최적화

1) 카테고리 → IR로 확정

3) 프롬프트

emotion 카테고리의 보기
: Urgently, Calmly, Slowly, ...

→ 감정보다는 행동의 태도와 속도

2) 프레임 샘플링

카테고리	문항 수	방식	프레임
single (HARn/HAU)	61 / 99	uniform	8
combination	95	uniform	8
multi	99	uniform	8
sequence	45	stratified (S1)	16
object_interaction	27	motion	8
emotion	99	motion	8

추론 구조 개선

1) multi → YES, NO

2) 답 생성 → logit

3) sequence 카테고리 : 단순 정렬 → stepwise 방식

모델 교체

실험	single	combination	emotion	multi	sequence	object_interac tion	전체
대조군 (TTA OFF)	0.637	0.589	0.303	0.242	0.111	0.37	0.4324 (n=525)
기준 (Qwen2.5-VL)	0.625	0.611	0.343	0.242	0.111	0.37	0.4400 (n=525)
Qwen3-VL-8B	0.662	0.674	0.253	0.394	0.267	0.444	0.4914 (n=525)
LLaVA-OneVision-7B	0.625	0.621	0.303	0.283	0.311	0.519	0.4667 (n=525)
Gemma3-12B	0.613	0.653	0.293	0.364	0.178	0.556	0.4724 (n=525)
Phi-4	0.463	0.558	0.313	0.172	0.133	0.444	0.3676
InternVL3.5-4B	0.681	0.632	0.313	0.393	0.311	0.407	0.5029
카테고리 라우팅	0.662	0.674	0.253	0.394	0.311	0.444	0.4952
양상블	0.644	0.684	0.273	0.333	0.267	0.593	0.4876

최종 리더보드 성능

41	letterhill	  	0.53508	11	8d
Your latest submission scored 0.51169. Your best score remains 0.53508.					

아쉬운 점

1. 모델 교체를 너무 늦게 시도
2. non-visual 센서 데이터 활용
3. LoRA fine-tuning
4. multi, emotion, sequence 카테고리의 처리

**THANK YOU FOR
LISTENING**